

**PENGEMBANGAN SISTEM REKOMENDASI ADAPTIF
REAL-TIME UNTUK DESTINASI WISATA: OPTIMALISASI
KEBERAGAMAN DAN CAKUPAN GUNA MENDORONG
PEMERATAAN DISTRIBUSI PARIWISATA**

TESIS

**Karya tulis sebagai salah satu syarat
untuk memperoleh gelar Magister dari
Institut Teknologi Bandung**

**Oleh
M EGYPT PRATAMA
NIM: 2523311
(Program Studi Magister Informatika)**



**INSTITUT TEKNOLOGI BANDUNG
Maret 2025**

ABSTRAK
PENGEMBANGAN SISTEM REKOMENDASI ADAPTIF
REAL-TIME UNTUK DESTINASI WISATA: OPTIMALISASI
KEBERAGAMAN DAN CAKUPAN GUNA MENDORONG
PEMERATAAN DISTRIBUSI PARIWISATA

Oleh
M Egypt Pratama
NIM: 23523311
(Program Studi Magister Informatika)

ABSTRACT

***PENGEMBANGAN SISTEM REKOMENDASI ADAPTIF REAL-
TIME UNTUK DESTINASI WISATA: OPTIMALISASI
KEBERAGAMAN DAN CAKUPAN GUNA MENDORONG
PEMERATAAN DISTRIBUSI PARIWISATA***

By

M Egypt Pratama

NIM: 23523311

(Program Studi Magister Informatika)

**PENGEMBANGAN SISTEM REKOMENDASI ADAPTIF
REAL-TIME UNTUK DESTINASI WISATA: OPTIMALISASI
KEBERAGAMAN DAN CAKUPAN GUNA MENDORONG
PEMERATAAN DISTRIBUSI PARIWISATA**

Oleh
M Egypt Pratama
NIM: 23523311
(Program Studi Magister Informatika)

Institut Teknologi Bandung

Menyetujui
Tim Pembimbing

Tanggal 2025

Pembimbing I

Dr. Ir. Arry Akhmad Arman, M.T.

PEDOMAN PENGGUNAAN TESIS

Tesis Magister yang tidak dipublikasikan terdaftar dan tersedia di Perpustakaan Institut Teknologi Bandung, dan terbuka untuk umum dengan ketentuan bahwa hak cipta ada pada penulis dengan mengikuti aturan HaKI yang berlaku di Institut Teknologi Bandung. Referensi kepustakaan diperkenankan dicatat, tetapi pengutipan atau peringkasan hanya dapat dilakukan seizin penulis dan harus disertai dengan kaidah ilmiah untuk menyebutkan sumbernya.

Sitasi hasil penelitian Tesis ini dapat di tulis dalam bahasa Indonesia sebagai berikut:

Nama Belakang, Inisial Nama Depan. (Tahun): *Judul tesis*, Tesis Program Magister, Institut Teknologi Bandung.

dan dalam bahasa Inggris sebagai berikut:

Nama Belakang, Inisial Nama Depan. (Tahun): *Judul tesis yang telah diterjemahkan dalam bahasa Inggris*, Master's Thesis, Institut Teknologi Bandung.

Memperbanyak atau menerbitkan sebagian atau seluruh tesis haruslah seizin Dekan Sekolah Pascasarjana, Institut Teknologi Bandung.

KATA PENGANTAR

Penulis panjatkan puji dan syukur kepada Allah Swt. karena atas rahmat dan karunia-Nya penulis mampu menyelesaikan laporan Tesis ini yang berjudul “.....”. Penyusunan laporan Tesis ini bertujuan untuk memenuhi mata kuliah IF6098 Tesis 2 dan untuk memenuhi syarat kelulusan tingkat magister di program studi Magister Informatika Institut Teknologi Bandung.

Pada kesempatan ini, penulis pun ingin mengucapkan terima kasih kepada berbagai pihak yang terlibat terkait penelitian Tesis ini karena telah memberikan dukungan dan bantuan dalam pelaksanaannya. Ucapan terima kasih penulis ucapkan kepada:

1. Bapak Dr. Ir. Arry Akhmad Arman, M.T. selaku dosen pembimbing yang telah membimbing dan memberikan masukan dan saran kepada penulis dalam menyelesaikan penelitian Tesis,
2. Dosen Penguji 1
3. Dosen Penguji 2
4. Dosen Wali
5. Dosen Pengajar Tesis 2
6. Tim Tesis Magister Informatika STEI ITB yang telah membimbing dalam pengurusan kebutuhan administrasi dan persiapan menjelang Seminar dan Sidang Tesis,
7. Karyawan dan staf dari TU STEI ITB yang telah membantu kebutuhan administrasi dalam menyelesaikan laporan Tesis dan membantu kebutuhan penulis selama mengikuti pembelajaran di ITB,
8. Kepada istri dan anak
9. Kepada keluarga
10. Kepada Komdigi selaku pemberi beasiswa
11. Teman-teman Smart-x
12. Pihak-pihak lain yang tidak dapat disebutkan satu per satu yang turut serta untuk membantu penulis untuk menyelesaikan Tesis.

Bandung, 2025

Penulis

DAFTAR ISI

BAB I. Pendahuluan	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	5
I.3 Tujuan Penelitian	5
I.4 Ruang Lingkup Masalah	6
I.5 Kebaruan dan Kontribusi	7
I.6 Hipotesis.....	7
I.7 Sistematika Penulisan	8
BAB II. Tinjauan Pustaka	10
II.1 Sistem Rekomendasi dalam Ekosistem Pariwisata Digital.....	10
II.2 Tantangan Sistem Rekomendasi Konvensional: <i>Popularity Bias</i>	11
II.3 Paradigma Evaluasi 'Beyond Accuracy': Keberagaman dan Cakupan	14
II.4 Analisis Kritis MMR dan Integrasi MAB.....	17
II.5 Menuju Sistem Adaptif: Keterbatasan Pendekatan Statis.....	19
II.6 Rangkuman Tinjauan Pustaka dan Posisi Penelitian	22
BAB III. Metodologi Penelitian.....	25
III.1 Metode Penelitian DSRM.....	25
III.2 Identifikasi Masalah dan Motivasi	27
III.3 Menentukan Solusi dari Tujuan.....	28
III.3.1 Integrasi MAB-MMR.....	28
III.3.2 Arsitektur Solusi Multi-Tahap Adaptif.....	29
III.3.3 Spesifikasi Teknis Solusi.....	29
III.4 Perancangan dan Pengembangan.....	30
III.4.1 Arsitektur Sistem.....	30
III.4.2 Desain Microservices dan Scalability	32
III.4.3 Integrasi Data dan API.....	33
III.4.4 Strategi Real-time Data Processing.....	34
III.4.5 Desain Model Machine Learning.....	34
III.4.6 Arsitektur Hybrid Model.....	35
III.4.7 Multi-Armed Bandit untuk Parameter λ Optimization	37
III.4.8 Strategi Concept Drift Detection dan Model Adaptation..	39
III.4.9 Tools dan Teknologi	40
III.5 Demonstrasi	40
III.5.1 Skenario Demonstrasi Real-World	41
III.5.2 Metrik Demonstrasi.....	41
III.6 Evaluasi	42
III.6.1 Model Pembandingan (Baseline).....	42
III.6.2 Metrik Evaluasi Kuantitatif.....	43
III.6.3 Metrik Evaluasi Kualitatif.....	44
III.6.4 Protokol Eksperimen.....	45
III.7 Komunikasi.....	46
BAB IV. Analisis Dan Perancangan Sistem	47
IV.1 Tahap Analisis Sistem	47
IV.1.1 Analisis Permasalahan	47

IV.1.2 Analisis Sistem Serupa.....	47
IV.1.3 Analisis Kebutuhan Data.....	47
IV.2 Spesifikasi Kebutuhan Sistem	47
IV.2.1 Kebutuhan Fungsional	47
IV.2.2 Kebutuhan Non-Fungsional	48
IV.3 Tahap Perancangan Sistem.....	48
IV.3.1 Perancangan Arsitektur Sistem	48
IV.3.2 Perancangan Basis Data	48
IV.3.3 Perancangan Modul dan Proses	49
IV.3.4 Perancangan Algoritma Inti Rekomendasi.....	49
IV.3.5 Perancangan Antarmuka Pengguna.....	49
IV.4 Spesifikasi Kebutuhan Perangkat Keras dan Perangkat Lunak...	49
BAB V. Implementasi dan Evaluasi Sistem	50
V.1 Implementasi Sistem	50
V.2 Dataset yang Digunakan	50
V.3 Metodologi Evaluasi	50
BAB VI. Kesimpulan dan Saran	51
VI.1 Kesimpulan.....	51
VI.2 Saran	51

DAFTAR LAMPIRAN

DAFTAR GAMBAR DAN ILUSTRASI

Gambar II.1 Alur Konseptual Penelitian.....	24
Gambar III.1 Kerangka Kerja DSRM berdasarkan Peffers dkk (2007).....	25
Gambar III.2 Kerangka Penelitian	27
Gambar III.3 Arsitektur Sistem Rekomendasi Adaptif Real-Time.....	30

DAFTAR TABEL

Tabel III.1 Spesifikasi Integrasi Data dan API	33
Tabel III.2 Tools dan Teknologi Penelitian	40

DAFTAR SINGKATAN DAN LAMBANG

SINGKATAN	Nama	Pemakaian pertama kali pada halaman
API	Application Programming Interface	Hal. 31
DSRM	Design Science Research Methodology	Hal. 25
MAB	Multi-Armed Bandit	Hal. 4
MAE	Mean Absolute Error	Hal. 14
ML	Machine Learning	Hal. 32
MMR	Maximal Marginal Relevance	Hal. 3
NDCG	Normalized Discounted Cumulative Gain	Hal. 5
ODTW	Objek Daya Tarik Wisata	Hal. 31
RMSE	Root Mean Squared Error	Hal. 14
RS	Recommender Systems	Hal. 7
LAMBANG	Deskripsi	Halaman
λ	hyperparameter yang mengontrol keseimbangan antara akurasi (Scoreprediksi) dan keberagaman	Hal. 39
γ	bobot yang mengontrol intensitas fungsi koreksi bias.	Hal. 39
μ	global mean rating	Hal. 35
u_i	user	Hal. 35
b_i	item biases	Hal. 35
c	parameter eksplorasi.	Hal. 38
$\hat{\mu}(t,k)$	estimated reward mean	Hal. 38
$N(t,k)$	number of times arm k dipilih	Hal. 38
$pop(i)$	popularity score dari item i	Hal. 44
q_i, p_u	latent factor vectors	Hal. 35
S	set rekomendasi	Hal. 44
$sim(i,j)$	similarity antara item i dan j.	Hal. 44

LAMBANG	Deskripsi	Halaman
W	learned weights untuk masing-masing kategori <i>contextual features</i>	Hal. 36

BAB I. Pendahuluan

Bab ini menjelaskan dasar-dasar yang membantu dalam melakukan penelitian ini. Dasar pemikiran didasarkan pada fenomena masalah yang muncul dan dibahas dalam penelitian setelah membaca sumber referensi yang tersedia.

I.1 Latar Belakang

Industri pariwisata digital menghadapi paradoks fundamental yang mengancam esensi eksplorasi wisata itu sendiri. Meskipun teknologi informasi membuka akses ke ribuan destinasi yang beragam dan otentik, sistem rekomendasi konvensional justru menghasilkan konsentrasi wisatawan yang tidak berkelanjutan pada segelintir destinasi populer Pencarelli, (2020) dan Ricci dkk., (2022) menggarisbawahi fenomena ini. Dampak dari paradoks tersebut tidak hanya mengikis autentisitas pengalaman wisata, tetapi juga menimbulkan distorsi ekonomi sistematis dalam ekosistem pariwisata global.

Konsentrasi wisatawan memicu ketidakseimbangan ekonomi yang merugikan. Menurut UNWTO, (2021), 10 destinasi teratas menampung 40% kedatangan wisatawan global dan 10 negara dengan penerimaan tertinggi menguasai hampir 50% pendapatan pariwisata dunia, dengan Amerika Serikat sendiri mencapai USD 214 miliar (UNWTO, 2021) . Ketergantungan berlebih ini membuat wilayah tertentu sangat rentan, misalnya Makau di mana pariwisata menyumbang 48% PDB, serta Spanyol dan Kroasia lebih dari 10% PDB. Sebaliknya, potensi daerah lain kerap terabaikan, sehingga pemerintah beberapa negara, seperti Belanda, mendorong kebijakan penyebaran wisatawan ke luar kota besar (Hu dkk., 2020). Dalam konteks digital, bias algoritma yang lebih sering merekomendasikan destinasi populer (*popularity bias*) memperparah ketimpangan ini, sekaligus menyulitkan UKM lokal di destinasi alternatif untuk bersaing (Massimo & Ricci, 2022).

Secara sosial, konsentrasi wisatawan yang tidak merata menciptakan gesekan di lokasi populer dan mengabaikan potensi pengembangan komunitas di tempat lain (Hoarau-Heemstra dkk., 2023). Di destinasi *mainstream*, kepadatan berlebih atau *overtourism* menurunkan kualitas pengalaman turis dan mengganggu kehidupan penduduk lokal melalui kemacetan, kebisingan, dan beban infrastruktur yang berat (Hoarau-Heemstra dkk., 2023). Fenomena *overtourism* ini juga mengarah pada penurunan kualitas pengalaman wisatawan akibat kepadatan berlebih dan terbatasnya daya dukung kawasan (Foronda-Robles dkk., 2025). Investasi pun cenderung terpusat di wilayah populer, meninggalkan destinasi potensial lainnya dengan fasilitas yang kurang memadai (Hoarau-Heemstra dkk., 2023). Lebih jauh lagi, komersialisasi pariwisata massal berisiko mengikis keaslian budaya lokal di destinasi populer, sehingga menimbulkan ketegangan antara kebutuhan ekonomi dan pelestarian warisan (Siyamiyan Gorji dkk., 2026). Sementara itu, destinasi alternatif yang kurang dikunjungi kehilangan peluang untuk mengembangkan interaksi budaya yang lebih berkelanjutan (Hoarau-Heemstra dkk., 2023). Oleh karena itu, distribusi wisatawan yang tidak merata tidak hanya memperburuk beban sosial di destinasi utama, tetapi juga menghambat potensi pembangunan komunitas di wilayah lain (Hoarau-Heemstra dkk., 2023).

Data empiris dari ekosistem pariwisata Kabupaten Sumedang memperkuat pola amplifikasi algoritmik yang diprediksi dalam literatur. DISPARBUDPORA, (2024) melaporkan distribusi kunjungan yang sangat timpang: dari 77 destinasi terdaftar, 72,4% total kunjungan terpusat pada hanya 10 destinasi populer (13% dari total destinasi), menghasilkan distribusi Pareto yang jauh lebih ekstrem dibandingkan rasio klasik 80/20..

Dominasi destinasi *mainstream* menunjukkan pola yang konsisten dengan temuan tentang *popularity bias*, di mana item-item populer cenderung direkomendasikan secara berlebihan bahkan kepada pengguna yang minatnya lebih ke arah item *niche* atau kurang populer (Abdollahpouri dkk., 2021). Fenomena ini menyebabkan item-item populer mendominasi rekomendasi yang diberikan kepada semua pengguna (Abdollahpouri dkk., 2021). Menara Kujang Sapasang menerima 306.333

kunjungan (18,2% dari total kunjungan kabupaten), sementara OW Janspark mencatat 249.579 kunjungan (14,8%). Kontras yang mencolok terlihat pada destinasi berpotensi tinggi namun terabaikan: Kampung Adat Cikondang hanya menerima 8.450 kunjungan (0,5%), meskipun menawarkan authentic cultural experience yang unik. Museum Prabu Geusan Ulun, yang memiliki nilai historis tinggi, hanya dikunjungi 14.232 wisatawan (0,8% dari total).

Fenomena '*popularity bias*' menjadi akar permasalahan dalam algoritma rekomendasi konvensional. Sistem berbasis *Collaborative Filtering* cenderung memperkuat preferensi mayoritas sehingga menciptakan siklus “yang kaya semakin kaya”, di mana destinasi populer mendapat visibilitas berlebih sementara destinasi bernilai tinggi namun kurang terekspos terpinggirkan hal ini dijelaskan oleh Abdollahpouri dkk., (2021). Menurut temuan mereka, kurang dari 3% item dapat mendominasi 100% rekomendasi pada sistem *Item-Collaborative Filtering*, dan dominasi mencapai 99% pada User-Collaborative Filtering (Abdollahpouri dkk., 2021).

Konsekuensi bias algoritmik melampaui masalah teknis semata. Dalam ruang pariwisata, Barykin dkk., (2021) serta Solano-Barliza, Arregocés-Julio, dkk., (2024) menunjukkan bagaimana popularity bias berkontribusi pada overtourism yang merusak destinasi populer secara paralel, Ricci dkk., (2022) menyoroti munculnya “gurun ekonomi” pada destinasi potensial yang terabaikan. Konsentrasi wisatawan yang tidak berkelanjutan mengikis autentisitas budaya lokal dan menciptakan ketimpangan ekonomi regional operator pariwisata skala kecil seringkali kehilangan akses pasar akibat algorithmic invisibility.

Upaya mitigasi popularity bias melalui teknik diversifikasi memperlihatkan hasil yang menjanjikan. Yalcin & Bilge, (2021) misalnya, melaporkan bahwa *Maximal Marginal Relevance* (MMR) mampu meningkatkan keberagaman rekomendasi dengan mengoptimalkan trade-off antara relevansi dan dissimilarity; dalam kerangka MMR, parameter lambda ($\lambda \in [0,1]$) mengatur keseimbangan tersebut $\lambda=0$ menekankan relevansi murni dan $\lambda=1$ memaksimalkan keberagaman tanpa

mempertimbangkan relevansi. Namun demikian, nilai λ yang bersifat statis menghadapi keterbatasan dalam konteks pariwisata yang dinamis: optimalitas λ bersifat kontekstual dan dapat berubah secara drastis berdasarkan kondisi real-time.

Perubahan konteks seperti fluktuasi cuaca, kepadatan pengunjung, atau viral trends pada media sosial memengaruhi preferensi relevansi versus diversitas Shi dkk., (2023) dan Yoon & Choi, (2023) menyoroti dinamika konteks semacam ini. Ketika cuaca beralih dari cerah menjadi hujan lebat, misalnya, prioritas relevansi untuk destinasi outdoor meningkat sementara untuk atraksi indoor prioritas diversitas dapat meningkat kondisi seperti ini menuntut mekanisme adaptif yang mampu menyesuaikan λ secara real-time.

Multi-Armed Bandit (MAB) menawarkan kerangka pembelajaran online yang relevan untuk masalah adaptasi parameter tersebut. Sebagai framework yang mengoptimalkan exploration–exploitation trade-off guna memaksimalkan expected reward dalam lingkungan tidak pasti, MAB memungkinkan setiap 'arm' merepresentasikan konfigurasi λ yang berbeda sehingga sistem dapat menyesuaikan tingkat diversifikasi berdasarkan feedback pengguna dan perubahan faktor lingkungan secara berkelanjutan (Shi dkk., 2023).

Meskipun potensi integrasi MAB dengan teknik diversifikasi seperti Maximal Marginal Relevance (MMR) telah diidentifikasi, implementasi sistematis untuk optimasi parameter dinamis dalam lingkungan streaming data multimodal pariwisata belum dieksplorasi secara komprehensif. Gap penelitian ini menandai area riset penting dalam pengembangan sistem rekomendasi pariwisata adaptif yang dapat menjawab tantangan distribusi tidak merata sekaligus mempertahankan kualitas rekomendasi.

I.2 Rumusan Masalah

Berikut merupakan rumusan masalah yang akan dibahas dalam penelitian ini:

1. Bagaimana optimasi dinamis parameter λ pada MMR menggunakan *Multi-Armed Bandit* dapat meningkatkan keberagaman dan cakupan rekomendasi tanpa mengorbankan akurasi?
2. Seberapa besar pengaruh integrasi data real-time (cuaca, kepadatan wisatawan, dan sentimen media sosial) dalam mendorong pemerataan distribusi kunjungan pariwisata, khususnya dengan mengangkat destinasi kurang terekspos, diukur melalui pengurangan koefisien Gini dan peningkatan Coverage@K?
3. Sejauh mana sistem rekomendasi multi-tahap adaptif dapat meningkatkan eksposur destinasi kurang populer dibandingkan sistem konvensional, diukur melalui metrik *Novelty*, *rasio long-tail coverage*, dan evaluasi kepuasan pengguna (*user acceptance*)?

I.3 Tujuan Penelitian

Tujuan utama penelitian ini adalah mengembangkan sistem rekomendasi pariwisata adaptif dengan optimasi *Multi-Armed Bandit* yang tidak hanya mempertahankan akurasi (Precision@K, NDCG) tetapi juga meningkatkan keberagaman, cakupan (*coverage*), dan novelty destinasi, sehingga mendukung pemerataan distribusi kunjungan pariwisata dengan mengangkat destinasi kurang terekspos dalam berbagai kondisi real-time (cuaca, kepadatan wisatawan, sentimen media sosial). Beberapa tujuan spesifik yang dicapai dalam rangka mendukung tujuan utama adalah:

1. Mengembangkan mekanisme optimasi parameter *Multi-Armed Bandit* pada *Maximal Marginal Relevance* dan memvalidasi dampaknya terhadap peningkatan keberagaman (*Intra-List Diversity*) dan pengurangan bias popularitas (*Gini coefficient*), serta mempertahankan akurasi (Precision@K, NDCG).

2. Menerapkan integrasi data kontekstual real-time (cuaca, kepadatan wisatawan, sentimen media sosial) dalam sistem rekomendasi untuk menilai sejauh mana keragaman dan cakupan destinasi dapat ditingkatkan dengan response time $<200\text{ms}$.
3. Merancang dan menguji sistem rekomendasi multi-tahap adaptif yang diukur melalui metrik novelty (*popularity-based*), coverage@K, serta evaluasi pengguna (*user acceptance*), untuk menilai dampaknya terhadap eksposur destinasi kurang populer.

I.4 Ruang Lingkup Masalah

Untuk meningkatkan fokus dari penelitian, diperlukan beberapa batasan dalam penyelesaian masalah penelitian. Berikut merupakan batasan masalah dari penelitian ini.

1. Penggunaan data real-time meliputi pembaruan cuaca, kondisi lalu lintas, penanggalan, dan tren media sosial.
2. Penelitian difokuskan pada destinasi wisata di Kabupaten Sumedang.
3. Analisis dilakukan terhadap tingkat keberagaman dan cakupan rekomendasi destinasi.
4. Evaluasi performa sistem mencakup metrik *Precision@K*, *NDCG*, *Gini Coefficient*, *Intra-List Diversity*, *Coverage@K*, dan *Novelty*.
5. Evaluasi berbasis pengguna dilakukan melalui user testing dengan pengamatan langsung terhadap interaksi pengguna.
6. Sistem diuji menggunakan simulasi data historis tanpa deployment production
7. Evaluasi terbatas pada rekomendasi destinasi wisata (tidak termasuk akomodasi).

I.5 Kebaruan dan Kontribusi

Adapun kebaruan dan kontribusi penelitian ini adalah sebagai berikut.

1. Penelitian ini mengembangkan metode rekomendasi pariwisata adaptif yang menggunakan *streaming data* kontekstual *real-time* sebagai parameter dinamis untuk mengurangi *popularity bias* dan meningkatkan eksposur destinasi kurang populer

I.6 Hipotesis

Hipotesis utama yang menjadi fokus penelitian ini adalah terkait dengan optimasi parameter Multi-Armed Bandit pada Maximal Marginal Relevance, integrasi data kontekstual real-time, dan implementasi sistem rekomendasi pariwisata adaptif. Penelitian ini bertujuan untuk mengatasi popularity bias dalam sistem rekomendasi pariwisata dan meningkatkan eksposur destinasi kurang populer dengan tetap mempertahankan akurasi rekomendasi.

1. "Optimasi parameter dinamis menggunakan Multi-Armed Bandit pada Maximal Marginal Relevance (MAB-MMR) menghasilkan keberagaman rekomendasi yang lebih tinggi secara signifikan dibandingkan pendekatan parameter statis, sambil mempertahankan tingkat akurasi yang sebanding."
2. "Integrasi data kontekstual real-time (cuaca, kepadatan wisatawan) menyebabkan penurunan popularity bias yang signifikan, yang diukur melalui penurunan koefisien Gini dan peningkatan metrik Coverage@K."
3. "Sistem rekomendasi multi-tahap adaptif yang diusulkan secara holistik menghasilkan peningkatan eksposur destinasi kurang populer yang diukur melalui metrik Novelty dan cakupan long-tail yang signifikan dibandingkan sistem rekomendasi konvensional."

Dari beberapa premis tersebut, didapat hipotesis yang mencerminkan fokus utama penelitian ini, yaitu:

"Implementasi Multi-Armed Bandit untuk optimasi parameter dinamis pada Maximal Marginal Relevance yang dikombinasikan dengan streaming data kontekstual real-time dapat secara efektif mengatasi popularity bias, meningkatkan

keberagaman dan cakupan destinasi, serta mempertahankan akurasi prediktif dalam sistem rekomendasi pariwisata adaptif."

Melalui sistem rekomendasi multi-tahap adaptif dengan pembelajaran berkelanjutan, penelitian ini diharapkan dapat mengatasi keterbatasan fundamental parameter statis dan memberikan solusi komprehensif untuk distribusi kunjungan pariwisata yang lebih merata. Dengan demikian, penelitian ini diharapkan tidak hanya berkontribusi pada pengembangan teknologi sistem rekomendasi adaptif, tetapi juga memberikan framework sistematis untuk mengintegrasikan pembelajaran adaptif dengan streaming data multimodal dalam domain pariwisata yang inheren dinamis.

I.7 Sistematika Penulisan

Dalam penyusunan tesis ini, penulis terbagi menjadi lima bab dengan penjabaran untuk masing-masing bab sebagai berikut.

BAB I Pendahuluan

Bab ini membahas mengenai latar belakang masalah, rumusan masalah, maksud dan tujuan, batasan masalah, metodologi penelitian, dan sistematika penulisan yang digunakan.

BAB II Tinjauan Pustaka

Bab ini membahas mengenai konsep dasar serta teori-teori yang berkaitan dengan topik penelitian dan hal-hal yang berguna dalam proses analisis permasalahan.

BAB III Metodologi Penelitian

Bab ini berisi tentang metodologi penelitian yang digunakan dalam melakukan penelitian serta dijelaskan metode yang dilakukan setiap tahapan mulai dari awal sampai dengan akhir.

BAB IV Analisis Dan Perancangan Sistem

Bab ini menyajikan arsitektur teknis, algorithm design, dan implementation strategy dengan justifikasi untuk setiap design decision.

BAB V Implementasi dan Evaluasi Sistem

Bab ini berisi dokumentasikan eksperimen komprehensif, statistical analysis, dan interpretation of results dalam konteks research questions yang telah diformulasikan.

BAB VI Kesimpulan dan Saran

Bab ini merangkum temuan utama, acknowledge limitations, dan menyajikan future research directions yang spesifik dan actionable.

BAB II. Tinjauan Pustaka

Tinjauan pustaka dalam penelitian ini membahas teori-teori yang mendasari pengembangan sistem rekomendasi pariwisata adaptif. Bagian ini mencakup kajian teori, penelitian terdahulu, serta kerangka pemikiran yang menjadi dasar dalam perancangan sistem.

II.1 Sistem Rekomendasi dalam Ekosistem Pariwisata Digital

Menurut Barykin et al., (2021), industri pariwisata telah mengalami transformasi digital yang fundamental, sebuah proses yang dipercepat oleh berbagai peristiwa global yang menyoroti urgensi integrasi teknologi. Studi tersebut menekankan bahwa solusi teknologi menjadi krusial agar industri ini dapat tumbuh lebih tangguh dan berkelanjutan. Sebagai konsekuensinya, para pelaku industri dituntut untuk meningkatkan kehadiran e-commerce, menawarkan pengalaman digital yang inovatif, dan mengoptimalkan strategi pemasaran destinasi mereka (Barykin dkk., 2021).

Namun, ironisnya, pertumbuhan data yang eksponensial di internet ((Huang dkk., 2020); (Alfaifi, 2024)) justru menciptakan fenomena paradoksal, yaitu kelebihan informasi atau information overload ((Kumar dkk., 2024); (Sachi Nandan Mohanty, 2020)). Paradoks ini secara fundamental menghambat kemampuan pengguna untuk mengakses konten yang relevan dengan cepat (Huang dkk., 2020) dan menjadikan pencarian rekomendasi yang benar-benar sesuai sebagai sebuah tantangan kompleks (Kumar dkk., 2024). Oleh karena itu, sistem rekomendasi hadir sebagai alat mitigasi yang krusial, dirancang khusus untuk mengelola surplus informasi ini dan memfasilitasi pengambilan keputusan yang lebih optimal bagi pengguna ((Gotthardt & Mezhuyev, 2022); (Ko dkk., 2022)).

Dengan demikian, peran strategis Sistem Rekomendasi (SR) melampaui sekadar mekanisme penyelesaian masalah kelebihan informasi (Shuvo & Islam, 2024). Lebih dari itu, SR berfungsi sebagai pendorong pergeseran paradigma dalam perilaku wisatawan dari pemrosesan informasi yang reaktif menuju kurasi

pengalaman yang proaktif. Kemampuan SR untuk menyediakan rekomendasi yang personal dan relevan, seperti yang ditekankan oleh Javadian Sabet et al., (2022) dan Ricci et al., (2022), serta beradaptasi sesuai situasi waktu nyata (Yoon & Choi, 2023), secara signifikan mengurangi beban kognitif wisatawan (Shambour dkk., 2024). Hal ini membebaskan kapasitas mental mereka untuk fokus pada aspirasi yang lebih mendalam: mencari pengalaman yang otentik (Shafqat & Byun, 2020), meningkatkan kepuasan, dan memperkaya pengalaman perjalanan (Choi dkk., 2021), bahkan mendukung pencapaian tujuan pariwisata berkelanjutan (Yoon & Choi, 2023).

Pergeseran menuju pencarian pengalaman ini diperkuat oleh data empiris yang kuat. Temuan bahwa 78% wisatawan global merasa 'lebih hidup' saat berlibur dan 68% merasa menjadi versi terbaik dari diri mereka Booking.com, (2023) mengindikasikan bahwa perjalanan telah berevolusi menjadi sebuah medium aktualisasi diri. Fenomena ini sejalan dengan konsep "Paradigma Pariwisata 2.0" yang, menurut Yoon & Choi, (2023) mengedepankan pengalaman budaya partisipatif daripada sekadar konsumsi.

Dalam konteks ini, kemampuan SR untuk menyaring dan mengarahkan pengguna ke item-item baru yang relevan (Ricci dkk., 2022) menjadi instrumen strategis (Gotthardt & Mezhuyev, 2022) untuk menerjemahkan aspirasi wisatawan menjadi rekomendasi yang otentik dan personal (Shambour dkk., 2024). Kemampuan SR untuk menawarkan atraksi yang dipersonalisasi berdasarkan analisis pola perjalanan dan preferensi, seperti yang dijelaskan oleh Choi et al., (2021), secara fundamental meningkatkan pengalaman wisatawan dan menjadikan perjalanan sebagai jalur yang lebih bermakna menuju pengembangan pribadi, sebuah tren yang sejalan dengan pantauan (World Tourism Organization, 2024).

II.2 Tantangan Sistem Rekomendasi Konvensional: *Popularity Bias*

Dalam lanskap sistem rekomendasi (SR) yang terus berkembang (Alfaifi, 2024), popularity bias atau bias popularitas menjadi sebuah fenomena sistemik yang signifikan. Bias ini menyebabkan item-item populer direkomendasikan secara tidak

proporsional dibandingkan item long-tail. Seperti yang diidentifikasi oleh (Yalcin & Bilge, 2021) serta (Abdollahpouri dkk., 2021), item niche tersebut mungkin sangat relevan bagi preferensi pengguna namun terabaikan. Kecenderungan intrinsik ini menghasilkan efek "yang kaya semakin kaya" (the rich get richer), di mana item-item populer secara sistematis diuntungkan (Abdollahpouri dkk., 2021). Akibatnya, konten populer mendapatkan visibilitas berlebihan yang kemudian meningkatkan konsumsinya secara eksponensial. Kondisi ini, menurut (Abdollahpouri, 2019) dan (Ricci dkk., 2022), menyebabkan marjinalisasi terhadap item-item niche, terutama yang baru, meskipun memiliki potensi relevansi yang tinggi.

Akar dari bias algoritmik ini terletak pada karakteristik fundamental algoritma itu sendiri, yang dilatih berdasarkan pola preferensi pengguna yang tidak terdistribusi secara merata ((Yalcin & Bilge, 2021); (Abdollahpouri dkk., 2020)). Sebagian besar pengguna cenderung mengevaluasi item-item tertentu saja, sementara item lainnya hanya menerima sedikit penilaian, sehingga menciptakan distribusi data yang timpang (Abdollahpouri dkk., 2021). Ricci et al., (2022) mengamati bahwa kondisi ini diperparah oleh kecenderungan mayoritas algoritma Collaborative Filtering (CF) yang memusatkan rekomendasi pada selera mayoritas, sehingga sering kali mengorbankan kebaruan dan keberagaman. Dalam analisisnya, Falk, (2019) menjelaskan bahwa sifat CF yang content-agnostic di mana rekomendasi didasarkan pada tren perilaku agregat turut memperkuat fenomena ini. Karena, seperti ditekankan oleh Falk, (2019), kesamaan (similarity) adalah basis komputasinya, item terpopuler secara statistik akan memiliki korelasi lebih tinggi dengan spektrum konten yang lebih luas. Temuan empiris dari Abdollahpouri et al., (2021) bahkan menegaskan kerentanan inheren SR berbasis CF, di mana kurang dari 3% item dapat mendominasi 100% rekomendasi pada Item-CF, dan konsentrasinya mencapai 99% pada User-CF.

Implikasi dari bias ini menjadi sangat kompleks dalam domain pariwisata, menghasilkan konsekuensi sosial seperti fenomena overtourism dan degradasi autentisitas destinasi ((Barykin dkk., 2021); (Solano-Barliza, Arregocés-Julio, dkk., 2024)). Destinasi yang sudah populer menerima penguatan bias melalui rekomendasi yang berlebihan, sehingga menciptakan konsentrasi wisatawan yang tidak berkelanjutan. Fenomena ini berkontribusi pada pembentukan "daftar pendek destinasi wisata yang menarik jutaan pelancong," sebuah istilah yang dikemukakan oleh Pencarelli, (2020). Tekanan demografis yang dihasilkan dari konsentrasi massal ini bahkan dapat menyebabkan perpindahan penduduk lokal dari pusat-pusat bersejarah karena area tersebut bertransformasi menjadi dominasi aktivitas turistik (Pencarelli, 2020). Ironisnya, wisatawan justru kehilangan pengalaman otentik yang mereka cari. Pada akhirnya, seperti yang dicatat oleh Pencarelli, (2020), kondisi ini merugikan baik penduduk maupun wisatawan dalam jangka panjang, menciptakan sebuah lingkaran degradasi di mana marginalisasi komunitas lokal secara langsung mengikis autentisitas, sebuah poin krusial yang juga diamati oleh Ricci et al., (2022).

Konsekuensi sosial tersebut merambat ke dalam struktur ekonomi regional. Bias popularitas menciptakan distorsi pasar yang sistematis, termanifestasi melalui konsentrasi pendapatan yang tidak proporsional di antara penyedia layanan pariwisata ((Abdollahpouri, 2019); (Ricci dkk., 2022)). Sebagai analogi dari domain hiburan, data empiris menunjukkan bahwa produk dari hanya 3 sutradara (kurang dari 0,4% dari total kreator) dapat mendominasi 50% dari seluruh rekomendasi (Ricci dkk., 2022). Dalam ekosistem pariwisata, pola konsentrasi serupa menyebabkan marginalisasi sistematis terhadap operator pariwisata skala kecil. Yoon & Choi, (2023) menambahkan bahwa keterbatasan akses data untuk destinasi yang kurang mapan semakin memperburuk siklus ini, menciptakan mekanisme yang terus-menerus memperkuat bias algoritmik. Ricci et al., (2022) berargumen bahwa kondisi ini jelas bertentangan dengan tujuan fundamental SR di industri pariwisata, yang idealnya berfungsi mendorong diversifikasi konsumsi dan penemuan produk long-tail. Oleh karena itu, penanganan bias popularitas menuntut intervensi yang melampaui optimisasi teknis semata, sebuah tantangan yang

menuntut kerangka kerja terintegrasi, sejalan dengan pemikiran Abdollahpouri, (2019) dan Ricci et al., (2022), untuk memastikan terciptanya ekosistem pariwisata yang lebih merata dan berkelanjutan.

II.3 Paradigma Evaluasi 'Beyond Accuracy': Keberagaman dan Cakupan

Shambour et al., (2024) mencatat bahwa evaluasi sistem rekomendasi (SR) secara historis sangat bertumpu pada metrik akurasi prediktif, seperti Mean Absolute Error (MAE) dan Root Mean Square Error (RMSE). MAE mengukur selisih absolut rata-rata antara prediksi dan rating aktual, sedangkan RMSE menjalankan fungsi serupa namun dengan memberikan bobot lebih pada kesalahan yang besar (Falk, 2019). Namun, studi oleh Choi et al., (2021) menunjukkan bahwa dalam konteks pariwisata yang kompleks, metrik akurasi tradisional ini menjadi tidak memadai.

Ricci et al., (2022) mengidentifikasi bahwa peningkatan marginal dalam akurasi yang dilaporkan dalam riset sering kali tidak berkorelasi dengan persepsi kualitas pengguna di dunia nyata. Akibatnya, sebuah SR dapat menunjukkan kinerja offline yang sangat baik, namun gagal dalam implementasi praktis karena tidak selaras dengan ekspektasi pengguna atau tujuan bisnis yang lebih luas (Ricci dkk., 2022). Keterbatasan ini juga terlihat dari ketidakmampuannya untuk secara inheren mengevaluasi rekomendasi item komposit, seperti paket tur (Choi dkk., 2021).

Bahkan, dalam beberapa aplikasi pariwisata, metrik seperti *precision* menjadi kurang relevan karena pengguna mungkin tidak diharapkan memilih lebih dari satu item. Fokus yang berlebihan pada akurasi juga cenderung memperkuat popularity bias, yang mengakibatkan sistem merekomendasikan item-item populer tanpa memberikan nilai tambah yang signifikan (Yalcin & Bilge, 2021). Dengan demikian, diperlukan paradigma evaluasi yang lebih holistik.

Melampaui akurasi, keberagaman muncul sebagai salah satu dimensi evaluasi yang esensial (Abdollahpouri dkk., 2020). Akhadam et al., (2025) mendefinisikan keberagaman sebagai lawan dari kesamaan, yang merujuk pada variasi item dalam sebuah daftar rekomendasi. Pengukuran keberagaman dapat dilakukan dengan

menghitung jarak rata-rata berpasangan antar semua item dalam set tersebut (Ricci dkk., 2022). Literatur kemudian membedakan dua jenis utama: intra-list diversity, yang mengukur perbedaan item untuk seorang pengguna, dan inter-list diversity, yang menilai perbedaan antar daftar rekomendasi untuk pengguna yang berbeda (Akhadam dkk., 2025). Pentingnya keberagaman didasari oleh beberapa argumen.

Sistem tradisional yang memprioritaskan kesamaan secara implisit mengabaikan keberagaman, sebuah kelalaian yang dapat menurunkan kualitas rekomendasi final (Ricci dkk., 2022). Rekomendasi yang beragam mampu memperkaya pengalaman pengguna seiring waktu, membantu mereka menemukan hal baru dan mengembangkan minat (Akhadam dkk., 2025). Tanpa keberagaman yang memadai, pengguna berisiko terperangkap dalam "gelembung filter" (filter bubble), di mana mereka hanya disajikan konten yang familier (Ricci dkk., 2022). Dalam konteks pariwisata, penerapan prinsip ini berarti merekomendasikan destinasi yang bervariasi secara geografis atau jenis aktivitas, bukan sekadar variasi minor pada lokasi yang sama (Shafqat & Byun, 2020).

Dimensi evaluasi krusial lainnya adalah kebaruan (novelty), yang merujuk pada sejauh mana item yang direkomendasikan belum pernah atau jarang dilihat oleh pengguna ((Abdollahpouri dkk., 2021); (Akhadam dkk., 2025)). Sementara keberagaman berfokus pada variasi karakteristik antar item, novelty memastikan pengguna terekspos pada konten atau pengalaman yang benar-benar baru dan tidak terduga ((Ricci dkk., 2022); (Abdollahpouri dkk., 2020)). Di domain pariwisata, novelty memiliki nilai strategis tinggi karena berkaitan dengan penemuan hidden gems destinasi non-mainstream dengan potensi pengalaman otentik (Abdollahpouri dkk., 2020). Sistem yang efektif menghasilkan rekomendasi novel dapat mendorong wisatawan keluar dari zona nyaman mereka, menemukan pengalaman yang tidak terjangkau melalui pencarian konvensional, sekaligus mengurangi popularity bias dengan mengeksplorasi item-item long-tail yang relevan (Abdollahpouri dkk., 2021).

Meskipun demikian, optimalisasi novelty menghadirkan dilema fundamental. Sebagaimana diperingatkan oleh (Falk, 2019), terlalu banyak novelty dapat mengorbankan relevansi, sementara terlalu sedikit akan membuat rekomendasi menjadi mudah ditebak. Oleh karena itu, tantangan utamanya terletak pada penciptaan keseimbangan dinamis antara novelty, keberagaman, dan relevansi. Hal ini menuntut sebuah pendekatan adaptif yang mampu menyesuaikan proporsi ketiga dimensi tersebut berdasarkan konteks dan preferensi individual pengguna (Ricci dkk., 2022).

Cakupan merupakan dimensi evaluasi fundamental berikutnya, yang mengindikasikan seberapa luas jangkauan item yang mampu direkomendasikan oleh sistem (Akhadam dkk., 2025). Konsep ini terbagi menjadi dua aspek: catalog coverage, yakni proporsi item dalam keseluruhan katalog, dan user coverage, atau proporsi pengguna yang dapat menerima rekomendasi (Akhadam dkk., 2025). Fungsi utama cakupan adalah untuk mengatasi masalah kelangkaan data (data sparsity) dan cold-start (Suhaim & Berri, 2021), dengan memungkinkan sistem menjangkau beragam item bahkan saat data interaksi masih terbatas (Alfaifi, 2024).

Dalam ranah pariwisata, riset oleh Ricci et al., (2022) menggarisbawahi kaitan langsung antara cakupan dengan promosi destinasi long-tail. Destinasi yang baru berkembang seringkali kali kekurangan data historis (Yoon & Choi, 2023), dan sistem dengan cakupan rendah akan cenderung mengabaikan aset potensial ini dan hanya berfokus pada item populer (Abdollahpouri dkk., 2021). Dengan demikian, peningkatan cakupan menjadi strategi vital untuk mendistribusikan perhatian ke item-item long-tail yang krusial bagi keberlanjutan ekonomi sektor pariwisata (Ricci dkk., 2022).

Sebagai kesimpulan, paradigma evaluasi "*beyond accuracy*" yang mengintegrasikan metrik seperti keberagaman dan cakupan menawarkan penilaian yang lebih komprehensif terhadap sistem rekomendasi pariwisata (Choi dkk., 2021). Lebih dari sekadar evaluasi teknis, pendekatan ini juga berfungsi sebagai penjaga ekosistem autentisitas destinasi. Tujuannya adalah memastikan sistem

rekomendasi berperan sebagai alat pelestarian bukan perusak terhadap keberagaman budaya dan ekonomi lokal yang menjadi esensi dari pariwisata itu sendiri (Ricci dkk., 2022).

II.4 Analisis Kritis MMR dan Integrasi MAB

Untuk mengatasi keterbatasan sistem rekomendasi konvensional, strategi teknis re-ranking telah muncul sebagai pendekatan yang valid secara metodologis (Yalcin & Bilge, 2021). Abdollahpouri, (2019) mendefinisikan re-ranking sebagai rekonfigurasi sistematis terhadap daftar kandidat rekomendasi, dengan tujuan fundamental untuk mengoptimalkan trade-off antara akurasi dan keberagaman (Yalcin & Bilge, 2021). Pendekatan ini mengimplementasikan intervensi algoritmik pada tahap post-processing, di mana item diberi bobot berbanding terbalik dengan popularitasnya, kemudian diorganisasi ulang berdasarkan kriteria diversifikasi (Abdollahpouri dkk., 2021).

Salah satu algoritma diversifikasi yang paling mapan adalah *Maximal Marginal Relevance* (MMR), yang menurut Yalcin & Bilge, (2021) beroperasi dengan prinsip optimisasi greedy untuk memaksimalkan kombinasi linear antara similarity terhadap preferensi pengguna dan dissimilarity terhadap item yang sudah terseleksi. Tujuan dari MMR, seperti dijelaskan oleh Shi et al., (2023), adalah mengoptimalkan relevansi sambil meminimalkan redundansi. Evaluasi kandidatnya didasarkan pada kriteria ganda: (1) tingkat relevansi terhadap preferensi pengguna (Noorian, 2024), dan (2) tingkat keberagaman relatif terhadap item yang sudah ada dalam set rekomendasi ((Shi dkk., 2023); (Zhao dkk., 2025)). Regulasi keseimbangan antara relevansi dan keberagaman ini dilakukan melalui parameter lambda ($\lambda \in [0,1]$) (Yalcin & Bilge, 2021), yang mengontrol trade-off antara kedua tujuan tersebut (Abdollahpouri dkk., 2021).

Meskipun demikian, pendekatan yang mengelola trade-off relevansi-diversitas seperti MMR menghadapi keterbatasan fundamental. Menurut Shi et al., (2023), kelemahannya berkaitan dengan asumsi parameter statis, di mana bobot optimal diasumsikan tidak bervariasi terhadap dinamika kontekstual. Dalam domain

pariwisata yang secara inheren tidak stabil, kondisi kontekstual seperti perubahan cuaca, transisi musim, atau acara lokal menuntut kalibrasi ulang yang adaptif ((Massimo & Ricci, 2022); (Qassimi & Rakrak, 2025)). Ketika kondisi berubah, sistem dengan parameter statis cenderung gagal beradaptasi, sehingga berpotensi menghasilkan rekomendasi yang suboptimal (Bukhari dkk., 2025).

Sebagai jawaban atas keterbatasan pendekatan statis, paradigma Multi-Armed Bandit (MAB) muncul sebagai kemajuan evolusioner yang menawarkan mekanisme pembelajaran adaptif dalam lingkungan dinamis ((Qassimi & Rakrak, 2025); (Ricci dkk., 2022)). Berbeda dengan konfigurasi parameter tetap, MAB beroperasi berdasarkan prinsip pembelajaran berkelanjutan (Qassimi & Rakrak, 2025), di mana sistem secara otonom menyesuaikan strategi berdasarkan umpan balik real-time (Shi dkk., 2023). Dalam arsitekturnya, setiap "arm" merepresentasikan strategi rekomendasi yang berbeda, dengan prioritas yang terdiferensiasi antara relevansi, kebaruan, atau pendekatan seimbang ((Ricci dkk., 2022); (Shi dkk., 2023); (Qassimi & Rakrak, 2025)).

Keunggulan komparatif MAB terletak pada kemampuan pembelajaran daring yang memungkinkannya beradaptasi tanpa bergantung pada data historis (Shi dkk., 2023); (Qassimi & Rakrak, 2025)). MAB dapat mengintegrasikan metrik diversifikasi dalam perhitungan *expected reward*, di mana fungsi imbalannya dirancang untuk menggabungkan kepuasan pengguna dengan ukuran peningkatan keberagaman ((Shi dkk., 2023); (Zhao dkk., 2025)). Ketika konteks berubah, sistem secara otomatis mengidentifikasi konfigurasi lengan yang optimal dan menyesuaikan probabilitas pemilihan strateginya ((Qassimi & Rakrak, 2025); (Bukhari dkk., 2025)).

Dalam lanskap algoritma diversifikasi yang lebih luas, pendekatan adaptif seperti *Multi-Armed Bandit* (MAB) menghadapi kompetisi dari metodologi lain (Shi dkk., 2023). Sementara itu, *Determinantal Point Processes* (DPP) menawarkan model probabilistik untuk meningkatkan keberagaman (Shi dkk., 2023). Di sisi lain, pendekatan berbasis kluster menawarkan efisiensi komputasi yang lebih baik

((Suhaim & Berri, 2021); (Nan dkk., 2022)), namun efektivitasnya sangat bergantung pada kualitas algoritma klastering yang digunakan (Chalkiadakis dkk., 2023).

Implementasi MAB dalam SR pariwisata memerlukan pertimbangan arsitektur yang canggih (Qassimi & Rakrak, 2025), termasuk desain fungsi imbalan yang kuat, strategi eksplorasi yang efisien, dan mekanisme adaptif untuk concept drift ((Qassimi & Rakrak, 2025); (Bukhari dkk., 2025)). Integrasi MAB dengan kerangka evaluasi komprehensif yang menggabungkan berbagai metrik keberagaman menjadi krusial untuk memastikan sistem tidak hanya responsif tetapi juga mempertahankan keadilan distribusi ((Abdollahpouri dkk., 2020); (Ricci dkk., 2022)). Pendekatan hibrida yang mengintegrasikan pembelajaran adaptif MAB dengan tujuan optimisasi keberagaman menawarkan kerangka solusi yang kuat untuk kompleksitas domain rekomendasi pariwisata modern ((Noorian, 2024); (Yoon & Choi, 2023); (Achmad dkk., 2023)).

II.5 Menuju Sistem Adaptif: Keterbatasan Pendekatan Statis

Sistem rekomendasi (SR) tradisional, yang beroperasi berdasarkan data historis dan pemodelan statis, menunjukkan keterbatasan signifikan dalam konteks dinamis karena kerap mengabaikan perubahan minat pengguna dari waktu ke waktu ((Wang dkk., 2022); (Bukhari dkk., 2025)). Akibatnya, sistem ini kesulitan merekomendasikan destinasi saat informasi tidak mencukupi atau berubah secara real-time ((Song & Jiao, 2023); (Yoon & Choi, 2023)). Yoon & Choi, (2023) bahkan mencatat bahwa SR berbasis kecerdasan buatan (AI) pun memiliki kelemahan serupa, karena gagal merefleksikan perubahan faktor eksternal seperti suhu atau curah hujan. Hal ini menggarisbawahi bagaimana sebagian besar model rekomendasi yang ada masih cenderung statis dalam beradaptasi terhadap perubahan lingkungan dan preferensi pengguna ((Shi dkk., 2023); (Bukhari dkk., 2025)).

Dalam riset pariwisata, pentingnya konteks real-time telah berulang kali ditekankan oleh berbagai peneliti ((Javadian Sabet dkk., 2022); (Yoon & Choi, 2023); (Qassimi & Rakrak, 2025)). Informasi situasional seperti suhu, curah hujan, atau musim menjadi faktor penentu signifikan dalam keputusan kunjungan dan dapat berubah seketika sesuai lokasi ((Yoon & Choi, 2023); (Solano-Barliza, Valls, dkk., 2024); (Shafqat & Byun, 2020)). Sebagai ilustrasi, sebuah sistem statis mungkin merekomendasikan jalur pendakian di pagi hari, tetapi sistem adaptif yang menerima data cuaca real-time akan membatalkan rekomendasi tersebut dan menyarankan museum jika prediksi cuaca menunjukkan akan turun hujan lebat (Qassimi & Rakrak, 2025). Oleh karena itu, sistem adaptif harus mampu merespons dinamika ini dengan merefleksikan perubahan faktor eksternal dan merekomendasikan tur yang disesuaikan dengan tipe wisatawan ((Yoon & Choi, 2023); (Qassimi & Rakrak, 2025)).

Pendekatan sadar konteks (*context-aware*) memperluas dimensi SR dari dua (pengguna, item) menjadi tiga (pengguna, item, konteks), sebuah ekspansi yang memungkinkan rekomendasi lebih akurat pada waktu dan lokasi yang tepat ((Suhaime & Berri, 2021); (Ricci dkk., 2022)). Pendekatan ini juga mempertimbangkan aktivitas dan bahkan kondisi emosional pengguna ((Suhaime & Berri, 2021); (Bukhari dkk., 2025)). Fararni et al., (2021) mengkategorikan konteks ini ke dalam beberapa jenis, termasuk informasi fisik (waktu, posisi, cuaca), sosial (keberadaan orang lain), dan media interaksi (karakteristik perangkat), sementara konteks modal seperti suasana hati menjadi pertimbangan penting lainnya (Bukhari dkk., 2025).

Untuk mendukung sistem adaptif yang sadar konteks, arsitektur streaming data menjadi sebuah keharusan fundamental (Bukhari dkk., 2025). Hal ini karena sistem konvensional cenderung statis dalam memodelkan preferensi pengguna (Noorian Avval & Harounabadi, 2023), sedangkan pendekatan adaptif seperti pembelajaran daring sangat penting untuk hasil yang kuat dalam skenario real-time (Bukhari dkk., 2025). Berbeda dengan pemrosesan batch yang beroperasi pada data historis dalam

interval tertentu, streaming data memungkinkan pemrosesan informasi secara berkelanjutan seiring kedatangan data baru (Fragkoulis dkk., 2024).

Perbedaan fundamental ini memiliki implikasi arsitektural yang signifikan antara pendekatan statis dan dinamis (Bukhari dkk., 2025). Dalam pendekatan tradisional berbasis batch, sistem hanya dapat merespons perubahan setelah siklus pemrosesan berikutnya, yang bisa memakan waktu berjam-jam atau berhari-hari karena ketergantungannya pada data historis yang statis ((Ricci dkk., 2022); (Shi dkk., 2023); (Bukhari dkk., 2025)). Sebaliknya, arsitektur streaming memungkinkan sistem untuk merespons perubahan konteks dalam hitungan detik, dengan fokus pada latensi rendah dan throughput tinggi (Fragkoulis dkk., 2024).

Implementasi streaming data dalam sistem rekomendasi (SR) pariwisata memerlukan kemampuan untuk menangani heterogenitas data yang tinggi (Solano-Barliza, Valls, dkk., 2024). Data ini mencakup data terstruktur seperti rating (Bukhari dkk., 2025) dan lokasi (Huang dkk., 2020), data semi-terstruktur seperti review (Ricci dkk., 2022), dan data tidak terstruktur seperti gambar atau video yang bersumber dari media sosial (Solano-Barliza, Valls, dkk., 2024). Stream processing framework harus mampu melakukan data fusion dari multiple sources secara simultan, mempertahankan low latency untuk responsivitas (Shafqat & Byun, 2020), dan menjamin fault tolerance untuk keandalan sistem dalam kondisi operasional yang tidak terduga (Fragkoulis dkk., 2024).

Namun, arsitektur stream processing saja tidak cukup jika model di dalamnya tidak mampu belajar dari data yang terus mengalir Fragkoulis. Di sinilah konsep pembelajaran adaptif atau berkelanjutan menjadi komplemen yang vital ((Ricci dkk., 2022); (Qassimi & Rakrak, 2025)). Sistem tidak hanya harus memproses data baru dengan cepat, tetapi juga secara bertahap memperbarui model tanpa perlu melatih ulang dari awal ((Shi dkk., 2023); (Fragkoulis dkk., 2024)). Konsep ini memungkinkan sistem untuk terus belajar dari pola-pola baru, mengingat preferensi pengguna dan faktor kontekstual dapat mengalami concept drift pada interval yang tidak terduga ((Wang dkk., 2022); (Shi dkk., 2023)).

II.6 Rangkuman Tinjauan Pustaka dan Posisi Penelitian

Tinjauan pustaka yang telah disajikan mengungkap sebuah progresi logis dari masalah fundamental hingga celah penelitian yang kritis dalam ekosistem rekomendasi pariwisata digital. Abdollahpouri et al., (2021) mengidentifikasi popularity bias sebagai tantangan utama sistem rekomendasi konvensional, di mana dominasi destinasi populer menciptakan pengalaman wisata yang homogen dan menghambat eksplorasi personal yang bermakna. Kondisi ini dikonfirmasi oleh penelitian terbaru yang menunjukkan dampak signifikan terhadap keberagaman pengalaman wisata ((Zhao dkk., 2025); (Shi dkk., 2023)).

Dalam upaya mengatasi keterbatasan ini, teknik diversifikasi seperti *Maximal Marginal Relevance* (MMR) telah terbukti berhasil meningkatkan keberagaman rekomendasi. Namun, sebagaimana diungkap oleh Shi et al., (2023), pendekatan-pendekatan existing ini cenderung menggunakan parameter statis dan mengabaikan karakteristik dinamis interaksi. Manifestasi problematik ini terlihat ketika sistem gagal beradaptasi pada perubahan konteks yang drastis seperti perubahan cuaca mendadak yang mengharuskan transisi dari aktivitas outdoor ke indoor (Noorian, 2024).

Karakteristik inheren dinamis dari domain pariwisata (Huang dkk., 2020) menuntut sistem yang mampu merespons perubahan konteks real-time (Nan dkk., 2022). Tinjauan komprehensif terhadap penelitian kontemporer mengungkap bahwa upaya-upaya existing masih belum efektif dalam mengintegrasikan data multimodal (Wang dkk., 2022) dan aspek temporal secara kohesif untuk mencapai adaptasi yang benar-benar responsif.

Berdasarkan analisis sintesis ini, celah penelitian yang teridentifikasi secara eksplisit adalah ketiadaan kerangka sistematis yang mampu mengintegrasikan pemrosesan data multimodal real-time dengan pembelajaran adaptif berkelanjutan. Juan et al., (2024) menekankan pentingnya integrasi data multimodal real-time, sementara Qassimi & Rakrak, (2025) mengadvokasi pembelajaran berkelanjutan sebagai solusi adaptasi sistem. *Convergent evidence* menunjukkan kebutuhan akan

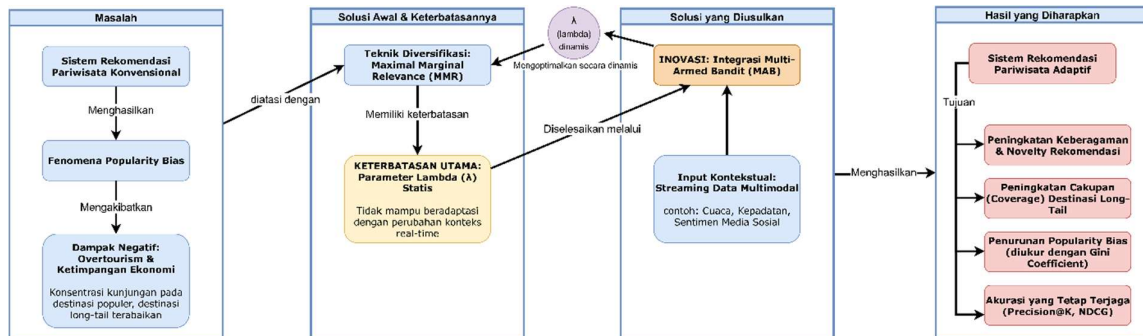
sistem yang sekaligus personal (Noorian Avval & Harounabadi, 2023), beragam (Shi dkk., 2023), dan adaptif terhadap perubahan konteks yang cepat (Bukhari dkk., 2025).

Untuk mengatasi gap fundamental ini, tesis ini mengusulkan kerangka kerja rekomendasi adaptif yang secara efektif menggabungkan aliran data multimodal dari berbagai sumber, mengintegrasikan mekanisme pembelajaran adaptif dan stream processing untuk menyesuaikan rekomendasi secara on-the-fly berdasarkan perubahan preferensi pengguna dan faktor lingkungan eksternal, serta mempertimbangkan aspek personalisasi mendalam dan keberagaman untuk menciptakan pengalaman wisata yang lebih cerdas dan responsif.

Sebagai sintesis dari keseluruhan tinjauan pustaka yang telah diuraikan, progresi logis penelitian ini dapat divisualisasikan dalam sebuah kerangka konseptual. Kerangka ini memetakan alur penelitian secara sistematis, dimulai dari identifikasi masalah fundamental yaitu fenomena popularity bias yang mengakibatkan overtourism dan ketimpangan ekonomi dalam sistem rekomendasi konvensional. Selanjutnya, dipaparkan analisis terhadap solusi diversifikasi yang ada seperti

Maximal Marginal Relevance (MMR), sekaligus menyoroti keterbatasan utamanya pada penggunaan parameter λ yang bersifat statis. Untuk mengatasi celah tersebut, penelitian ini mengusulkan sebuah inovasi berupa kerangka kerja adaptif yang mengintegrasikan *Multi-Armed Bandit (MAB)*, yang secara dinamis mengoptimalkan parameter λ berdasarkan masukan dari streaming data kontekstual. Kerangka kerja ini dirancang untuk menghasilkan sebuah sistem rekomendasi pariwisata adaptif dengan tujuan holistik: tidak hanya mempertahankan akurasi, tetapi juga secara signifikan meningkatkan keberagaman,

cakupan destinasi long-tail, serta mengurangi bias popularitas. Alur konseptual penelitian secara lengkap disajikan pada Gambar 2.1.



Gambar II.1 Alur Konseptual Penelitian

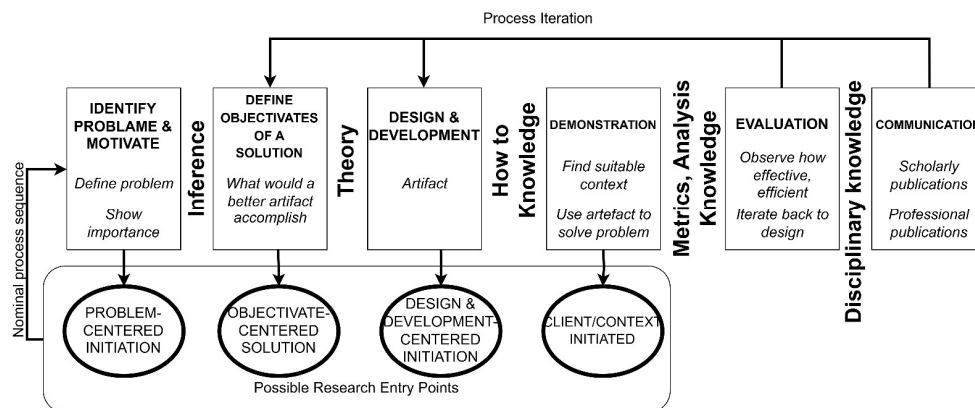
BAB III. Metodologi Penelitian

Bab ini akan menjelaskan metodologi penelitian yang diterapkan dalam pengembangan sistem rekomendasi adaptif real-time ini. Pendekatan *Design Science Research Methodology* (DSRM) dipilih sebagai kerangka kerja utama. Pembahasan dalam bab ini akan mencakup setiap tahapan DSRM, yaitu identifikasi masalah, penentuan tujuan solusi, perancangan dan pengembangan artefak, demonstrasi, evaluasi, serta komunikasi hasil penelitian.

III.1 Metode Penelitian DSRM

Penelitian ini menggunakan metode DSRM. DSRM adalah salah satu metode penelitian yang menyajikan setiap tahapan dengan mudah sehingga membantu dalam penelitian yang berhubungan dengan teknologi informasi dengan prinsip “pencarian solusi yang bertujuan” (Peffers dkk., 2007). Metode ini dapat digunakan untuk memahami dan melakukan evaluasi. DSRM terdiri dari enam tahapan mulai dari proses identifikasi terhadap masalah, menentukan solusi, melakukan perancangan dan pengembangan, melakukan demonstrasi, melakukan evaluasi, sampai dengan melakukan komunikasi seperti yang ditampilkan pada Gambar III.

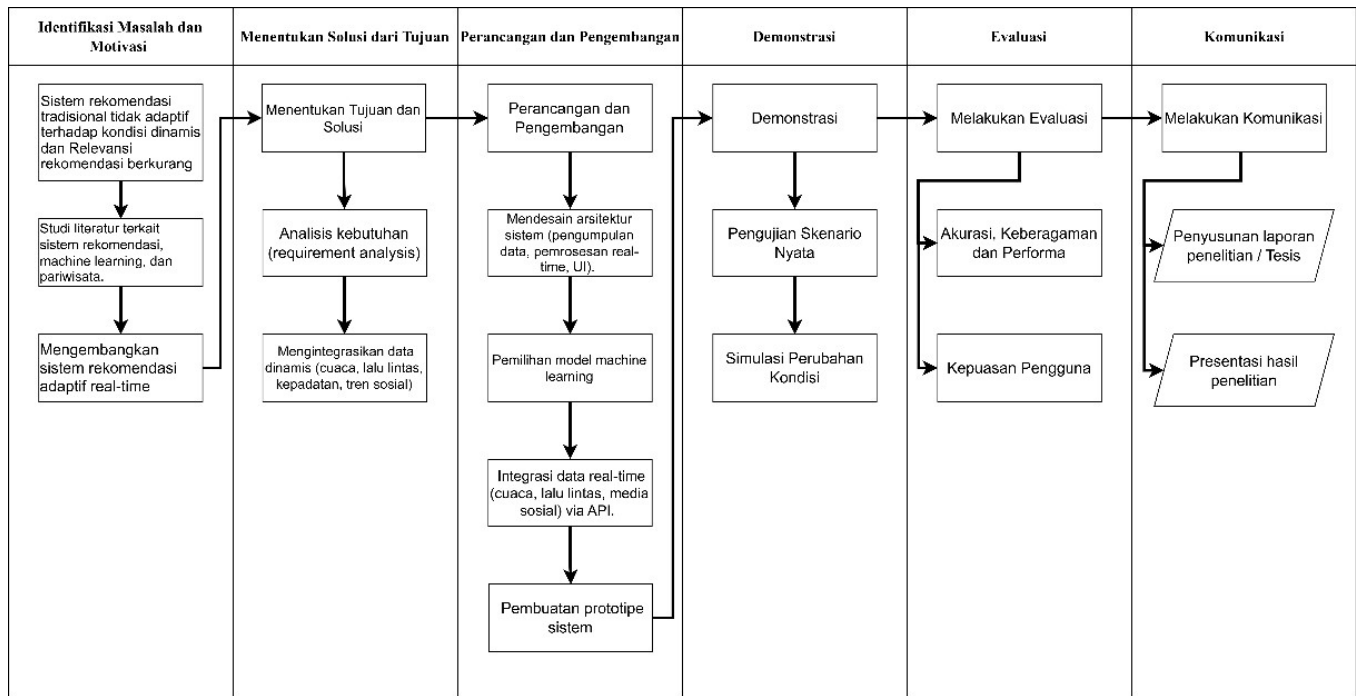
1.



Gambar III.1 Kerangka Kerja DSRM berdasarkan Peffers dkk (2007)

Pemilihan DSRM dalam penelitian ini didasarkan pada beberapa pertimbangan strategis yang selaras dengan karakteristik sistem rekomendasi adaptif yang dikembangkan. Pertama, DSRM memberikan kerangka kerja yang terstruktur untuk menggabungkan konsep teori dengan pembuatan sistem nyata, sebuah hal ini penting agar mengingat penelitian ini menggabungkan konsep teoritis *Multi-Armed Bandit* dengan aplikasi praktis dalam domain pariwisata yang dinamis. Kedua, sifat iteratif DSRM memungkinkan memperbaiki sistem berdasarkan feedback dari setiap tahap evaluasi, sangat relevan dengan sistem yang dikembangkan, yang memang bersifat adaptif dan terus belajar dari sistem yang dikembangkan. Ketiga, DSRM mendukung evaluasi dari berbagai sisi yang mencakup aspek teknis (akurasi, keberagaman, cakupan) dan aspek pengalaman pengguna (user acceptance, usability), selaras dengan paradigma evaluasi "beyond accuracy" yang telah diidentifikasi dalam tinjauan pustaka.

Berdasarkan kerangka DSRM, setiap tahapan penelitian telah diuraikan metode pelaksanaannya secara rinci guna memastikan penelitian berjalan secara terukur dan terencana. DSRM dipilih karena memungkinkan iterasi desain-evaluasi untuk sistem adaptif. Misalnya, tahap 'demonstrasi' pada DSRM memfasilitasi uji coba prototipe dalam skenario perubahan cuaca mendadak. Berikut kerangka penelitian yang digunakan dalam penelitian ini sebagaimana pada Gambar III 2.



Gambar III.2 Kerangka Penelitian

III.2 Identifikasi Masalah dan Motivasi

Penelitian ini dimulai dengan tahap Identifikasi Masalah dan Motivasi dalam kerangka DSRM. Tujuan utama dari tahap ini adalah menyoroti keterbatasan sistem rekomendasi pariwisata konvensional. Permasalahan utama terletak pada sifat statis sistem tersebut yang tidak mampu beradaptasi terhadap kondisi dinamis, seperti perubahan cuaca, kepadatan lalu lintas, hari libur pada penanggalan, atau tren yang sedang viral di media sosial. Akibatnya, relevansi dan kualitas rekomendasi yang diberikan cenderung menurun, serta sering kali hanya berfokus pada destinasi populer, mengabaikan banyak destinasi potensial lainnya.

Oleh karena itu, motivasi utama penelitian ini adalah untuk merancang, membangun, dan mengevaluasi sebuah sistem rekomendasi adaptif real-time yang tidak hanya memberikan rekomendasi yang lebih relevan secara kontekstual, tetapi juga secara terukur mampu menjawab tantangan terkait keberagaman, cakupan, dan penemuan destinasi baru tersebut.

III.3 Menentukan Solusi dari Tujuan

Setelah memetakan masalah dan merumuskan pertanyaan kunci, langkah selanjutnya adalah mendefinisikan seperti apa bentuk solusi yang akan dibangun untuk menjawabnya. Bagian ini akan menguraikan konsep dan arsitektur solusi yang diusulkan. Visi utamanya adalah membangun sebuah sistem rekomendasi adaptif real-time yang berfungsi sebagai solusi inovatif.

III.3.1 Integrasi MAB-MMR

Solusi yang diusulkan menggabungkan dua teknik: *Multi-Armed Bandit* (MAB) untuk pembelajaran adaptif dan *Maximal Marginal Relevance* (MMR) untuk meningkatkan keberagaman rekomendasi. MMR beroperasi dengan prinsip optimisasi greedy untuk memaksimalkan kombinasi linear antara similarity terhadap preferensi pengguna dan dissimilarity terhadap item yang sudah terseleksi (Yalcin & Bilge, 2021). Ide dasarnya adalah mengatasi kelemahan parameter λ yang tetap dalam MMR tradisional (Shi et al., 2023) dengan mengoptimalkannya secara dinamis berdasarkan umpan balik real-time dari lingkungan menggunakan pendekatan MAB yang memungkinkan pembelajaran berkelanjutan (Qassimi & Rakrak, 2025).

Dalam formulasi ini, setiap "arm" dalam MAB merepresentasikan konfigurasi parameter λ yang berbeda dalam spektrum continuous $[0,1]$ (Shi dkk., 2023). Algoritma MAB secara adaptif memilih nilai λ optimal berdasarkan *reward function* yang mengintegrasikan beberapa sumber: kepuasan pengguna (diukur melalui CTR), peningkatan keragaman (diukur melalui *intra-list diversity*), dan peningkatan cakupan (diukur melalui cakupan katalog) (Bauer dkk., 2024). *Expected reward* untuk setiap arm k pada waktu t diformulasikan sebagai:

$$E[R_{t,k}] = \alpha \cdot SAT_{t,k} + \beta \cdot DIV_{t,k} + \gamma \cdot COV_{t,k}$$

dimana α , β , γ adalah bobot yang mengontrol kontribusi relatif dari setiap komponen objective, dan nilai-nilai tersebut dapat disesuaikan berdasarkan karakteristik domain aplikasi dan preferensi strategis sistem.

III.3.2 Arsitektur Solusi Multi-Tahap Adaptif

Tujuan dari sistem yang akan dikembangkan ini adalah untuk secara langsung menjawab pertanyaan penelitian yang telah diajukan. Secara spesifik, sistem ini dirancang untuk mencapai hal-hal berikut:

1. Sistem harus mampu mengintegrasikan berbagai sumber data dinamis untuk membuktikan bahwa pendekatan adaptif dapat meningkatkan metrik diversity dan coverage secara signifikan, seraya mempertahankan atau bahkan meningkatkan performa metrik akurasi dan relevansi (F1-score, Precision, Recall) dibandingkan model baseline statis.
2. Sistem yang dibangun harus memiliki modul streaming data yang dampaknya pada peningkatan diversity dapat diukur secara kuantitatif, sebagai proksi untuk mendorong visibilitas destinasi yang kurang populer.
3. Sistem harus dapat menunjukkan kemampuannya dalam menyajikan rekomendasi baru yang menarik bagi pengguna. Keberhasilan tujuan ini akan dievaluasi melalui metrik Novelty (seperti Popularity-based metrics) dan divalidasi melalui umpan balik kualitatif dari sesi user testing untuk mengukur peningkatan minat pada destinasi kurang populer.

III.3.3 Spesifikasi Teknis Solusi

Solusi teknis yang diusulkan menggunakan arsitektur microservices dengan pemisahan yang jelas antara komponen pengambilan data, model training, inference, dan optimization. Stream processing engine akan menggunakan Apache Kafka untuk real-time pengambilan data dengan Apache Flink sebagai processing framework untuk memastikan low-latency response (<200ms untuk inference requests).

Model machine learning akan diimplementasikan menggunakan hybrid approach yang menggabungkan *collaborative filtering* (menggunakan *matrix factorization techniques*) dengan *content-based filtering* untuk *foundational relevance scoring*, kemudian diaugmentasi dengan *contextual features* dari streaming data sources. MAB *optimization layer* akan diimplementasikan menggunakan *Upper Confidence*

Bound (UCB) algorithm untuk balance antara exploration dan exploitation dalam parameter λ selection.

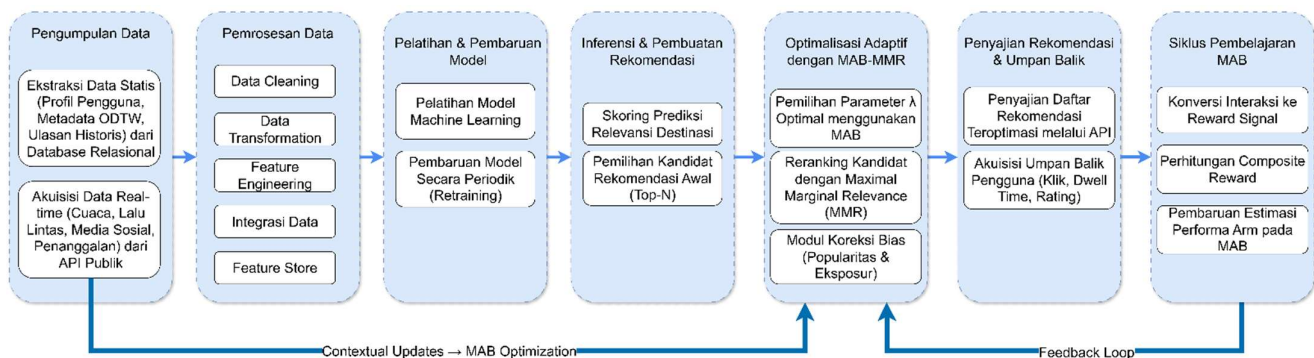
Dengan demikian, tujuan solusi ini menjadi landasan yang terukur untuk seluruh proses perancangan, pengembangan, dan evaluasi sistem penelitian, memastikan bahwa setiap komponen yang dibangun berkontribusi langsung pada pembuktian hipotesis yang tersirat dalam rumusan masalah.

III.4 Perancangan dan Pengembangan

Tahap Perancangan dan Pengembangan merupakan inti dari DSRM, di mana sistem solusi mulai dibangun secara teknis. Berdasarkan tujuan yang telah dirumuskan pada sub-bab sebelumnya, sistem yang dikembangkan dalam penelitian ini adalah sebuah sistem rekomendasi pariwisata adaptif real-time. Bagian ini akan menjelaskan cetak biru teknis dari sistem tersebut, mencakup arsitektur sistem, strategi integrasi data, desain model machine learning, serta perangkat dan teknologi yang digunakan.

III.4.1 Arsitektur Sistem

Perancangan sistem menggunakan arsitektur pipeline data yang menyeluruh, sebagaimana telah dimodelkan secara konseptual pada Gambar III.3. Arsitektur ini dirancang untuk memproses data secara sistematis melalui tujuh tahapan utama, guna memastikan efisiensi dan kapabilitas pembelajaran berkelanjutan. Proses operasional sistem, dari permintaan awal hingga penyajian rekomendasi, dieksekusi melalui alur kerja berikut:



Gambar III.3 Arsitektur Sistem Rekomendasi Adaptif Real-Time

1. Tahap 1: Pengumpulan Data: Proses dimulai dengan mengambil dua kategori data. Data real-time mencakup cuaca, lalu lintas, tren media sosial, dan penanggalan diambil dari API publik secara terjadwal dengan format yang terstruktur untuk MAB processing. Secara paralel, data statis meliputi profil pengguna, metadata Objek Daya Tarik Wisata (ODTW), dan ulasan historis diekstraksi dari basis data relasional.
2. Tahap 2: Pemrosesan Data: Data mentah yang telah diakuisisi selanjutnya melalui tahap pra-pemrosesan yang meliputi pembersihan data (data cleaning) untuk menangani anomali, transformasi data, dan rekayasa fitur (feature engineering) untuk mengekstraksi variabel prediktif termasuk *contextual signals* untuk MAB *reward calculation*. Seluruh fitur ini kemudian diintegrasikan menjadi dataset terpadu yang siap digunakan untuk pemodelan.
3. Tahap 3: Pelatihan & Pembaruan Model: Model machine learning dilatih menggunakan dataset terpadu. Arsitektur ini didesain untuk mendukung mekanisme pelatihan ulang secara periodik, guna memastikan adaptasi model terhadap pergeseran pola data.
4. Tahap 4: Inferensi & Pembuatan Rekomendasi: Pada saat inferensi, model yang telah dilatih digunakan untuk menghasilkan skor prediksi relevansi untuk setiap destinasi bagi pengguna aktif. Berdasarkan skor tersebut, sejumlah destinasi dengan peringkat teratas dipilih sebagai himpunan kandidat rekomendasi awal.
5. Tahap 5: Optimalisasi Adaptif dengan MAB-MMR: Tahap ini merupakan inti inovasi penelitian yang mengimplementasikan sistem optimalisasi dua lapis. Layer pertama: Multi-Armed Bandit (MAB) menganalisis kondisi kontekstual real-time dari Tahap 1 (cuaca, traffic, social trends) untuk memilih parameter λ optimal dari 11 kemungkinan nilai (0.0, 0.1, ..., 1.0) menggunakan Upper Confidence Bound policy. Layer kedua: Maximal Marginal Relevance menggunakan λ terpilih untuk me-rerank kandidat dengan menyeimbangkan relevansi dan diversity secara dinamis, serta mengimplementasikan modul koreksi bias untuk memitigasi bias popularitas dan mempromosikan destinasi yang kurang terekspos.

6. Tahap 6: Penyajian Rekomendasi & Umpan Balik: Daftar N-Top ODTW yang telah teroptimalkan disajikan kepada pengguna melalui sebuah endpoint API.
7. Tahap 7: Siklus Pembelajaran MAB: Interaksi pengguna (click, dwell time, rating) dikonversi menjadi reward signal untuk MAB. Sistem menghitung composite reward: $\alpha \cdot CTR + \beta \cdot Diversity_gain + \gamma \cdot Coverage_improvement$ untuk setiap pilihan λ . Data reward ini digunakan MAB untuk memperbarui estimasi performa setiap arm, menciptakan pembelajaran berkelanjutan yang mengoptimalkan parameter λ seiring waktu, sehingga membentuk sebuah siklus pembelajaran berkelanjutan.
8. Integrasi Real-time: Tahap 1 (Pengumpulan data) secara kontinyu memberikan contextual updates ke Tahap 5 (MAB Optimization), menciptakan closed-loop system dimana kondisi eksternal secara langsung mempengaruhi parameter optimization. Pembelajaran Berkelanjutan: Tahap 7 (Feedback) memberikan reward signal ke MAB di Tahap 5, memungkinkan sistem 'belajar' kombinasi λ yang optimal untuk setiap konteks spesifik.

III.4.2 Desain Microservices dan Scalability

Implementasi arsitektur sistem mengadopsi microservices pattern untuk memastikan scalability, maintainability, dan fault tolerance. Setiap komponen utama dipisahkan menjadi independent services:

1. Pengambilan data Service: Mengelola akuisisi data dari multiple sources dengan rate limiting dan error handling yang robust
2. *Feature Engineering Service*: Bertanggung jawab untuk transformasi data dan feature extraction
3. ML Model Service: Mengelola training, inference, dan model versioning
4. MAB Optimization Service: Mengimplementasikan Multi-Armed Bandit logic untuk parameter λ optimization
5. *Recommendation Engine*: Mengintegrasikan output dari semua services untuk menghasilkan final recommendations

6. *User Feedback Service*: Mengelola collection dan processing dari user interactions
7. Komunikasi antar services menggunakan event-driven architecture dengan Apache Kafka sebagai message broker, memungkinkan loose coupling dan asynchronous processing yang essential untuk real-time responsiveness.

III.4.3 Integrasi Data dan API

Untuk merealisasikan kapabilitas adaptif sistem, penelitian ini mengintegrasikan empat sumber data dinamis utama yang diperoleh melalui API publik. Pemilihan sumber data ini diturunkan secara langsung dari rumusan masalah penelitian guna menangkap konteks perjalanan yang menyeluruh. Rincian API yang digunakan disajikan pada Tabel III.1.

Tabel III.1 Spesifikasi Integrasi Data dan API

No.	Sumber Data	API yang Digunakan	Data Point yang Diambil	Tujuan Penggunaan dalam Model
1	Cuaca Real-time	OpenWeatherMap API	Suhu, kelembaban, curah hujan, kecepatan angin, visibility, kondisi cuaca	Context-aware filtering untuk destinasi outdoor vs indoor
2	Lalu Lintas & Mobilitas	Google Maps Traffic API	Kondisi lalu lintas real-time, estimasi waktu perjalanan, kepadatan jalan	Optimalisasi routing dan accessibility scoring
3	Media Sosial	X API	Mention count, sentiment score, trending hashtags,	Popularity trend detection dan viral content identification

			location-based posts	
4	Kalender & Event	Google Calendar API	Hari libur nasional/daerah, festival lokal, event musiman	Seasonal adjustment dan event-based recommendation boosting

III.4.4 Strategi Real-time Data Processing

Implementasi streaming data processing menggunakan Lambda Architecture yang menggabungkan batch processing untuk historical data dengan stream processing untuk real-time updates. Apache Kafka digunakan sebagai distributed streaming platform dengan partitioning strategy berdasarkan geographical regions untuk memastikan *scalability*.

Stream processing pipeline mengimplementasikan *windowing functions* untuk aggregasi data dalam time windows (5 menit, 15 menit, 1 jam) guna menangkap pattern temporal yang berbeda. Misalnya, perubahan cuaca sudden (5 menit window) vs trend cuaca harian (1 jam window) memerlukan response yang berbeda dalam parameter λ adjustment.

III.4.5 Desain Model Machine Learning

Desain model machine learning merupakan komponen penting yang secara langsung bertujuan menjawab pertanyaan penelitian. Model yang dikembangkan adalah Model Hibrida (*Collaborative, Content & Context-Aware*) yang diperkaya dengan modul Re-ranking dan Koreksi Bias.

Pendekatan ini dipilih berdasarkan pertimbangan berikut:

1. Fondasi Prediktif: Kombinasi *Collaborative Filtering* (CF) dan *Content-Based* (CB) memberikan dasar yang kuat untuk memprediksi relevansi berdasarkan interaksi pengguna dan atribut destinasi.
2. Kemampuan Adaptasi Kontekstual: Integrasi fitur real-time (cuaca, lalu lintas) memberikan kemampuan *Context-Aware*, memungkinkan sistem beradaptasi dengan kondisi saat ini.

3. Mekanisme Optimasi Multi-Metrik: Implementasi tahap re-ranking dan koreksi bias secara eksplisit ditujukan untuk menjawab Rumusan Masalah 1 dan 2, yaitu mengoptimalkan keberagaman dan cakupan di luar metrik akurasi tradisional.

III.4.6 Arsitektur Hybrid Model

Model hybrid mengintegrasikan tiga komponen utama dalam unified framework yang dirancang untuk memanfaatkan kekuatan masing-masing pendekatan sambil mengatasi kelemahan individual mereka.

- Komponen *Collaborative Filtering*

Komponen CF menggunakan *matrix factorization technique* (Singular Value Decomposition) untuk mengekstraksi latent factors dari user-item interaction matrix. Model CF menghasilkan baseline preference score berdasarkan similarity patterns dengan users lain:

$$ScoreCF(u, i) = \mu + bu + bi + qiTpu$$

dimana

μ = global mean rating

bu = user

bi = item biases

$qiTpu$ = latent factor vectors

Komponen ini menjawab pertanyaan "destinasi apa yang disukai oleh pengguna dengan preferensi serupa?"

- Komponen *Content-Based*

Komponen CB mengimplementasikan content similarity calculation berdasarkan destination features seperti kategori aktivitas (outdoor, cultural, culinary), geographical proximity, facility availability, dan price range. Similarity dihitung menggunakan cosine similarity pada TF-IDF vectors dari destination descriptions:

$$ScoreCB(u, i) = \cos(profile(u), features(i))$$

Komponen ini berfungsi untuk menjawab "seberapa cocok karakteristik destinasi dengan profil preferensi pengguna?"

- Komponen *Context-Aware*

Komponen *context-aware* merupakan kontribusi utama penelitian ini dalam mengintegrasikan informasi real-time untuk adaptasi sistem. Komponen ini mengolah empat kategori fitur kontekstual:

1. *Weather Features*: Mengolah data cuaca menjadi outdoor_suitability score, temperature comfort index, dan visibility rating untuk menentukan kesesuaian kondisi dengan jenis aktivitas destinasi.
2. *Traffic Features*: Menghitung travel_time_ratio, congestion_level, dan accessibility_score untuk memperkirakan kemudahan akses ke destinasi.
3. *Social Features*: Memproses mention velocity, sentiment score, dan trending coefficient dari media sosial untuk mengidentifikasi destinasi yang sedang populer atau viral.
4. *Temporal Features*: Mengintegrasikan hour of day, day type, seasonal weights, dan event indicators untuk penyesuaian rekomendasi berdasarkan waktu.

Setiap kategori fitur diproses melalui feature engineering yang menghasilkan normalized scores:

$$\begin{aligned} \text{ScoreContext}(u, i, c) \\ = \sigma(W_{\text{weather}} \cdot f_{\text{weather}} + W_{\text{traffic}} \cdot f_{\text{traffic}} \\ + W_{\text{social}} \cdot f_{\text{social}} + W_{\text{temporal}} \cdot f_{\text{temporal}}) \end{aligned}$$

dimana

c = current context vector

W = learned weights untuk masing-masing kategori *contextual features*.

- *Adaptive Weight Integration*

Final relevance score diperoleh melalui weighted combination dengan adaptive weights yang menyesuaikan kontribusi setiap komponen berdasarkan kondisi kontekstual:

$$\begin{aligned} \text{ScoreRelevance}(u, i, c) \\ = \alpha_{CF}(c) \cdot \text{ScoreCF} + \alpha_{CB}(c) \cdot \text{ScoreCB} + \alpha_{Context}(c) \\ \cdot \text{ScoreContext} \end{aligned}$$

dimana:

$$\alpha_{CF}(c) = \text{base_}\alpha_{CF} \times (1 + \text{weather_adjustment} + \text{traffic_adjustment})$$

$$\alpha_{CB}(c) = \text{base_}\alpha_{CB} \times (1 + \text{content_relevance_multiplier})$$

$$\alpha_{Context}(c) = \text{base_}\alpha_{Context} \times (1 + \text{contextual_urgency_factor})$$

Mekanisme adaptive weights memungkinkan sistem untuk secara otomatis menyesuaikan kepentingan relatif setiap komponen. Misalnya, ketika kondisi cuaca buruk, weight untuk context-aware component meningkat untuk memberikan pengaruh lebih besar pada indoor/outdoor suitability scoring.

- Integrasi dengan Streaming Data Pipeline

Context-aware component terintegrasi dengan streaming data pipeline yang memproses informasi real time dengan windowing strategy: 5 menit untuk weather data (high volatility), 15 menit untuk traffic data (medium volatility), dan 1 jam untuk social media trends (untuk menghindari noise dari fluktuasi jangka pendek). Sistem mengimplementasikan fallback mechanism menggunakan cached historical averages apabila data real-time tidak tersedia untuk memastikan continuous operation.

III.4.7 Multi-Armed Bandit untuk Parameter λ Optimization

Implementasi MAB menggunakan algoritma *Upper Confidence Bound* (UCB) untuk menyeimbangkan eksplorasi dan eksploitasi dalam memilih nilai λ optimal (Ricci et al., 2022). Setiap arm k merepresentasikan nilai λ yang di-diskritisasi dalam rentang $[0,1]$ dengan increment 0.1, menghasilkan 11 arm total. Pendekatan MAB dipilih karena kemampuan pembelajaran daring yang memungkinkannya beradaptasi tanpa bergantung pada data historis (Qassimi & Rakrak, 2025).

Reward function untuk setiap arm diformulasikan sebagai composite metric yang mengintegrasikan *user satisfaction*, *diversity improvement*, dan *coverage enhancement*:

$$\text{Reward}(t, k) = \alpha \cdot \text{CTR}(t, k) + \beta \cdot \Delta \text{Diversity}(t, k) + \gamma \cdot \Delta \text{Coverage}(t, k)$$

UCB selection policy memilih arm dengan highest upper confidence bound:

$$\text{UCB}(t, k) = \hat{\mu}(t, k) + c\sqrt{(\ln(t)/N(t, k))}$$

dimana

$\hat{\mu}(t, k)$ = estimated reward mean

$N(t,k)$ = number of times arm k dipilih

c = parameter eksplorasi.

Secara konseptual, proses pemodelan dieksekusi dalam dua fase utama:

1. Fase Generasi Kandidat: Pada fase ini, model hibrida CF-CB menghasilkan skor prediksi awal (Scoreprediksi) untuk setiap pasangan pengguna-destinasi, dengan memanfaatkan data historis dan statis.
2. Fase Re-ranking dan Koreksi Bias: Fase ini merupakan kontribusi utama penelitian dengan mengimplementasikan dua sub-proses yang terintegrasi:
Sub-proses 1: MAB Parameter Selection Multi-Armed Bandit menganalisis context vector yang mencakup kondisi cuaca, lalu lintas, tren media sosial, dan faktor temporal untuk memilih nilai λ_t optimal dari 11 arms ($\lambda \in [0.0, 0.1, \dots, 1.0]$) berdasarkan *Upper Confidence Bound policy*. Setiap arm merepresentasikan strategi berbeda dalam trade-off antara relevance dan diversity, dimana pemilihan didasarkan pada historical performance dalam konteks situasional yang serupa. Sub-proses 2: Adaptive MMR Re-ranking Menggunakan parameter λ_t yang dipilih oleh MAB, algoritma Maximal Marginal Relevance melakukan re-ranking dengan pendekatan adaptif.

Berbeda dengan implementasi MMR konvensional yang menggunakan parameter λ tetap, sistem ini mengimplementasikan Adaptive MMR dimana nilai λ_t berubah secara real-time berdasarkan:

1. Kondisi Kontekstual: Cuaca buruk atau kondisi traffic yang menghambat akses meningkatkan kebutuhan diversity (λ_t meningkat) untuk memberikan alternatif yang beragam
2. User Context: Pengguna baru memerlukan exploration tinggi (λ_t meningkat), sementara returning users dengan preferensi yang sudah jelas memerlukan prioritas relevance (λ_t menurun)
3. Environmental Dynamics: Viral events atau sudden popularity spikes memerlukan diversity maksimal untuk mencegah over-concentration pada destinasi trending.

Formula konseptual skor akhir setelah re-ranking untuk sebuah item i dalam daftar rekomendasi dapat direpresentasikan sebagai:

$$FinalScore_i = \lambda \cdot Scoreprediksi_i - (1 - \lambda) \cdot max_j \in S Sim(i, j) + \gamma \cdot Bonusbias_i$$

Di mana:

λ = hyperparameter yang mengontrol keseimbangan antara akurasi (Scoreprediksi) dan keberagaman.

$Sim(i, j)$ = fungsi kemiripan antara item kandidat i dan item j yang telah terpilih dalam daftar rekomendasi S .

γ = bobot yang mengontrol intensitas fungsi koreksi bias.

Bonusbiasi = nilai penyesuaian yang diterapkan pada item i berdasarkan tingkat popularitasnya.

III.4.8 Strategi Concept Drift Detection dan Model Adaptation

Untuk menangani concept drift dalam data pariwisata yang inherently volatile, sistem mengimplementasikan mekanisme deteksi drift menggunakan tes statistik pada distribusi fitur dan monitoring metrik performa (Wang et al., 2022). Pendekatan ini penting karena sistem konvensional cenderung statis dalam memodelkan preferensi pengguna dan kesulitan beradaptasi dengan perubahan yang cepat (Bukhari et al., 2025).

Ketika drift terdeteksi, sistem akan trigger adaptive retraining process dengan strategi:

1. *Incremental Learning*: Untuk gradual drift, model di-update menggunakan online learning techniques
2. *Full Retraining*: Untuk sudden drift, complete model retraining dengan extended historical window
3. *Ensemble Switching*: Untuk uncertain drift situations, sistem menggunakan ensemble of models dengan different time horizons.

III.4.9 Tools dan Teknologi

Realisasi teknis dari seluruh proses pengembangan dan eksperimen dalam penelitian ini didukung oleh serangkaian perangkat lunak dan pustaka (*libraries*) yang relevan dengan domain ilmu data dan rekayasa perangkat lunak. Rincian lengkap teknologi yang digunakan disajikan pada Tabel III.2.

Tabel III.2 Tools dan Teknologi Penelitian

No	Kategori	Teknologi/ Software	Versi	Peran dalam Penelitian
1	Programming Language	Python	3.9+	Primary development language untuk ML models dan data processing
2	Database	PostgreSQL	15.3	Relational data storage untuk user profiles dan destination metadata
3	API Framework	FastAPI	0.100.0	RESTful API development untuk recommendation endpoints
4	Containerization	Docker	24.0.2	Application containerization dan deployment
5	Orchestration	Docker Compose	2.18.1	Multi-container application orchestration
6	Version Control	Git	2.41.0	Source code management dan collaboration
7	Notebook Environment	Jupyter Lab	4.0.2	Interactive development dan experimentation
8	API Testing	Postman	10.15.1	API endpoint testing dan validation

III.5 Demonstrasi

Tahap Demonstrasi bertujuan untuk menunjukkan bagaimana sistem dapat digunakan untuk menyelesaikan permasalahan yang telah dirumuskan. Demonstrasi dilakukan melalui simulasi skenario nyata, seperti perubahan cuaca

mendadak, kemacetan lalu lintas, dan lonjakan kepadatan pengunjung. Tujuannya adalah untuk menilai kemampuan sistem dalam menyesuaikan rekomendasi secara adaptif.

III.5.1 Skenario Demonstrasi Real-World

Demonstrasi sistem akan dilakukan melalui simulasi berbagai skenario yang mencerminkan kondisi operasional sesungguhnya dalam domain pariwisata Kabupaten Sumedang:

1. **Skenario 1:** Simulasi cuaca hujan di Sumedang. Bayangkan seorang turis sedang merencanakan kunjungan ke Paralayang Batu Dua. Tiba-tiba, sistem mendeteksi prediksi hujan lebat dalam satu jam ke depan dari API cuaca. Dalam skenario ini, sistem diuji kemampuannya untuk beradaptasi. Harapannya, rekomendasi Paralayang akan otomatis turun peringkatnya, dan sistem akan menaikkan prioritas destinasi dalam ruangan yang relevan di sekitarnya, seperti Museum Prabu Geusan Ulun atau kafe-kafe unik di pusat kota.
2. **Skenario 2:** Simulasi sedang ada event musiman dan festival. Simulasi kondisi saat festival budaya berlangsung, di mana kepadatan wisatawan di destinasi tertentu meningkat drastis. Sistem diharapkan mampu mendiversifikasi rekomendasi ke destinasi alternatif yang sejenis untuk mengurangi overcrowding.
3. **Skenario 3:** Simulasi terhadap apa yang sedang viral. Melihat responsivitas sistem terhadap hal-hal yang viral dalam social media untuk destinasi tertentu, mengevaluasi kemampuan sistem dalam menangani antara merespons trend dan mempertahankan diversitas.

III.5.2 Metrik Demonstrasi

Setiap skenario akan dievaluasi menggunakan metrik real-time:

1. Response Time: Waktu yang dibutuhkan sistem untuk adaptasi (<200ms target)

2. Parameter Adjustment: Perubahan nilai λ optimal yang dipilih oleh MAB
3. Recommendation Diversity: Perubahan skor diversity sebelum dan sesudah adaptasi
4. User Satisfaction Proxy: Estimated click-through rate based pada historical patterns

Selain itu, prototipe diuji coba oleh sekelompok pengguna terbatas untuk memperoleh umpan balik awal terkait kegunaan, kenyamanan, dan relevansi hasil rekomendasi. Hasil demonstrasi menjadi validasi awal terhadap efektivitas sistem serta bahan pertimbangan untuk penyempurnaan pada tahap evaluasi.

III.6 Evaluasi

Tahap evaluasi merupakan fase kritis dalam siklus DSRM yang bertujuan untuk mengukur dan memvalidasi efektivitas sistem yang telah dikembangkan. Proses ini dirancang secara sistematis untuk menilai sejauh mana sistem rekomendasi adaptif real-time ini mampu memenuhi tujuan penelitian yang telah ditetapkan, khususnya dalam hal peningkatan keberagaman, cakupan, dan kebaruan, seraya mempertahankan akurasi. Evaluasi akan menggunakan pendekatan lengkap yang menggabungkan analisis kuantitatif berbasis metrik dan analisis kualitatif melalui pengujian pengguna.

III.6.1 Model Pemandangan (Baseline)

Untuk membuktikan bahwa model yang diusulkan benar-benar efektif, kinerjanya perlu dibandingkan dengan model yang lebih sederhana, yang disebut *baseline*. Dalam penelitian ini, ada dua baseline utama:

1. Baseline-POP (Popularity-based): Ini adalah model paling dasar yang hanya merekomendasikan tempat terpopuler. Model ini untuk memastikan bahwa sistem yang dibangun lebih baik daripada sekadar menyajikan "apa yang semua orang suka".
2. Baseline-CF (Standard Collaborative Filtering): Model ini dipilih untuk menjadi pembandingan yang adil. Dengan membandingkan model usulan (hibrida adaptif) dengan CF standar, diharapkan dapat melihat secara jelas seberapa besar peningkatan kinerja yang dihasilkan oleh penambahan data konteks *real-time* dan mekanisme *re-ranking* yang akan dikembangkan.

III.6.2 Metrik Evaluasi Kuantitatif

Evaluasi kuantitatif difokuskan untuk mengukur kinerja sistem secara objektif berdasarkan rumusan masalah. Metrik yang digunakan dikelompokkan ke dalam tiga kategori utama: (1) Akurasi dan Relevansi, (2) Keberagaman dan Cakupan, serta (3) Kebaruan.

Metrik akurasi dan relevansi digunakan untuk menjawab RM1, yaitu memvalidasi kemampuan sistem dalam mempertahankan kualitas rekomendasi.

- Precision@K: Mengukur proporsi item relevan dalam K item teratas yang direkomendasikan (Ricci et al., 2022). Metrik ini lebih praktis daripada precision tradisional karena fokus pada top-K recommendations yang benar-benar dilihat pengguna. Dihitung dengan formula:

$$Precision@K = |\{item\ relevan\} \cap \{top - K\ recommendations\}| / K$$

- NDCG (Normalized Discounted Cumulative Gain): Mengukur kualitas ranking dengan mempertimbangkan posisi item relevan dalam daftar rekomendasi (Ricci et al., 2022). Item relevan yang muncul di posisi atas mendapat skor lebih tinggi. NDCG dinormalisasi sehingga nilai maksimum adalah 1.0. Dihitung dengan formula:

$$NDCG@K = DCG@K / IDC@K$$

dimana

DCG@K = Discounted Cumulative Gain

IDCG@K = Ideal DCG.

Metrik keberagaman dan cakupan secara langsung mengukur keberhasilan sistem dalam menjawab RM1 dan RM2 terkait peningkatan variasi dan jangkauan rekomendasi.

- Diversity (Intra-List Diversity): Mengukur seberapa bervariasi item-item dalam satu daftar rekomendasi yang disajikan kepada seorang pengguna (Akhadam et al., 2025). Dalam penelitian ini, metrik ini dihitung sebagai 1 dikurangi rata-rata skor kemiripan antar item, sehingga nilai yang lebih

tinggi merepresentasikan keberagaman yang lebih baik. Dihitung berdasarkan formula:

$$Diversity = 1 - (2/(|S|(|S| - 1))) * \sum \sum sim(i, j)$$

dimana

S = set rekomendasi

sim(i,j) = similarity antara item i dan j.

- Coverage (Catalogue Coverage): Mengukur proporsi item dari keseluruhan katalog yang mampu direkomendasikan oleh sistem (Akhadam et al., 2025). Nilai yang lebih tinggi menunjukkan bahwa sistem tidak hanya terpaku pada sebagian kecil item populer, melainkan mampu menjangkau lebih banyak destinasi. Dihitung dengan formula:

$$Coverage = |\cup users Recommendations| / |Total Items|$$

Metrik Kebaruan ini digunakan untuk mengevaluasi kemampuan sistem dalam menjawab RM3, yaitu menyajikan destinasi yang tidak terduga atau kurang populer. Novelty (diukur via Popularity): Diukur melalui skor popularitas rata-rata dari item yang direkomendasikan (Abdollahpouri et al., 2021). Nilai popularitas yang lebih rendah mengindikasikan tingkat novelty yang lebih tinggi, karena hal tersebut menunjukkan sistem berhasil merekomendasikan item-item yang kurang terekspos. Dihitung dengan formula:

$$Novelty = -\sum(\log_2(pop(i))) / |Recommendations|$$

dimana

pop(i) = popularity score dari item i.

III.6.3 Metrik Evaluasi Kualitatif

Evaluasi kualitatif bertujuan untuk menggali persepsi dan pengalaman pengguna secara mendalam, yang tidak dapat ditangkap oleh metrik kuantitatif. Evaluasi ini akan dilakukan melalui sesi pengujian pengguna (user testing). Instrumen yang akan digunakan adalah:

1. *System Usability Scale* (SUS): Kuesioner standar industri yang terdiri dari 10 pertanyaan untuk mengukur persepsi kemudahan penggunaan (usability) dari prototipe sistem yang dibangun. Penggunaan SUS dalam penelitian

sejenis telah terbukti efektif, seperti yang ditunjukkan oleh Puspasari (2022).

2. Wawancara Semi-Terstruktur: Setelah sesi pengujian, wawancara akan dilakukan dengan setiap partisipan untuk menggali aspek-aspek spesifik seperti kepuasan pengguna, persepsi terhadap relevansi kontekstual rekomendasi (misalnya, saat cuaca berubah), dan ketertarikan terhadap destinasi kurang populer yang disajikan.

III.6.4 Protokol Eksperimen

Untuk memastikan proses evaluasi berjalan secara sistematis, dapat direplikasi, dan valid, penelitian ini akan mengikuti protokol eksperimen yang terstruktur sebagai berikut:

1. Persiapan Dataset: Dataset pariwisata Kabupaten Sumedang akan dipersiapkan dan dibagi menjadi dua himpunan secara acak: 80% sebagai data latih (training set) dan 20% sebagai data uji (test set).
2. Pelatihan Model: Ketiga model—dua model baseline (POP dan CF) dan satu model yang diusulkan (hibrida adaptif)—akan dilatih menggunakan data latih yang sama.
3. Generasi Rekomendasi: Untuk setiap pengguna dalam data uji, ketiga model akan digunakan untuk menghasilkan daftar N-Top rekomendasi (misal, $N=10$).
4. Kalkulasi Metrik Kuantitatif: Seluruh metrik kuantitatif yang telah didefinisikan (*Precision@K*, *NDCG*, *Diversity*, *Coverage*, dan *Novelty*) akan dihitung untuk setiap daftar rekomendasi yang dihasilkan oleh ketiga model.
5. Pelaksanaan Uji Kualitatif: Sesi user testing akan dilaksanakan dengan sekelompok pengguna representatif. Partisipan akan diminta untuk berinteraksi dengan prototipe sistem dan kemudian mengisi kuesioner SUS serta mengikuti sesi wawancara semi-terstruktur.
6. Analisis dan Interpretasi Hasil: Hasil dari metrik kuantitatif akan diintegrasikan dan dibandingkan antar model. Uji signifikansi statistik (misalnya, paired t-test) akan diterapkan untuk memvalidasi apakah perbedaan kinerja antara

model yang diusulkan dan model baseline signifikan secara statistik. Temuan dari data kualitatif akan dianalisis secara tematik untuk memberikan konteks dan penjelasan mendalam terhadap hasil kuantitatif.

III.7 Komunikasi

Tahap *Komunikasi* merupakan fase akhir dalam DSRM yang berfokus pada diseminasi hasil penelitian kepada komunitas akademik dan praktisi. Komunikasi dilakukan melalui penyusunan tesis yang mendokumentasikan seluruh proses, temuan, dan sistem secara lengkap.

DAFTAR PUSTAKA

- Abdollahpouri, H. (2019). Popularity bias in ranking and recommendation. *AIES 2019 - Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society*, 529–530. <https://doi.org/10.1145/3306618.3314309>
- Abdollahpouri, H., Mansoury, M., Burke, R., & Mobasher, B. (2020). The Connection between Popularity Bias, Calibration, and Fairness in Recommendation. *RecSys 2020 - 14th ACM Conference on Recommender Systems*, 726–731. <https://doi.org/10.1145/3383313.3418487>
- Abdollahpouri, H., Mansoury, M., Burke, R., Mobasher, B., & Malthouse, E. (2021). User-centered evaluation of popularity bias in recommender systems. *UMAP 2021 - Proceedings of the 29th ACM Conference on User Modeling, Adaptation and Personalization*, 119–129. <https://doi.org/10.1145/3450613.3456821>
- Achmad, F., Prambudia, Y., & Rumanti, A. A. (2023). Improving Tourism Industry Performance through Support System Facilities and Stakeholders: The Role of Environmental Dynamism. *Sustainability (Switzerland)*, 15(5). <https://doi.org/10.3390/su15054103>
- Akhadam, A., Kbibchi, O., Mekouar, L., & Iraqi, Y. (2025). A Comparative Evaluation of Recommender Systems Tools. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2025.3541014>
- Alfaifi, Y. H. (2024). Recommender Systems Applications: Data Sources, Features, and Challenges. Dalam *Information (Switzerland)* (Vol. 15, Nomor 10). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/info15100660>
- Barykin, S. E., de la Poza, E., Khalid, B., Kapustina, I. V., Kalinina, O. V., & Iqbal, K. M. J. (2021). Tourism industry: Digital transformation. Dalam *Handbook of Research on Future Opportunities for Technology Management Education* (hlm. 414–434). IGI Global. <https://doi.org/10.4018/978-1-7998-8327-2.ch025>
- Bauer, C., Zangerle, E., & Said, A. (2024). Exploring the Landscape of Recommender Systems Evaluation: Practices and Perspectives. *ACM Transactions on Recommender Systems*, 2(1), 1–31. <https://doi.org/10.1145/3629170>
- Booking.com. (2023). *SHARES ITS 7 PREDICTIONS FOR TRAVEL IN 2024 OUT OF AUTOPILOT AND INTO OUR BEST LIFE*.
- Bukhari, M., Maqsood, M., & Adil, F. (2025). An actor-critic based recommender system with context-aware user modeling. *Artificial Intelligence Review*, 58(5). <https://doi.org/10.1007/s10462-025-11134-9>
- Chalkiadakis, G., Ziogas, I., Koutsmanis, M., Streviniotis, E., Panagiotakis, C., & Papadakis, H. (2023). A Novel Hybrid Recommender System for the Tourism Domain. *Algorithms*, 16(4). <https://doi.org/10.3390/a16040215>

- Choi, I. Y., Ryu, Y. U., & Kim, J. K. (2021). A recommender system based on personal constraints for smart tourism city. *Asia Pacific Journal of Tourism Research*, 26(4), 440–453. <https://doi.org/10.1080/10941665.2019.1592765>
- DISPARBUDPORA. (2024). *DATA KUNJUNGAN OBJEK WISATA TAHUN 2023*.
- Falk, K. (2019). *Practical Recommender Systems*.
- Fararni, K. Al, Nafis, F., Aghoutane, B., Yahyaouy, A., Riffi, J., & Sabri, A. (2021). Hybrid recommender system for tourism based on big data and AI: A conceptual framework. *Big Data Mining and Analytics*, 4(1), 47–55. <https://doi.org/10.26599/BDMA.2020.9020015>
- Foronda-Robles, C., Galindo-Pérez-de-Azpillaga, L., & Armario-Pérez, P. (2025). The sustainable management of overtourism via user content. *Annals of Tourism Research Empirical Insights*, 6(2). <https://doi.org/10.1016/j.annale.2025.100184>
- Fragkoulis, M., Carbone, P., Kalavri, V., & Katsifodimos, A. (2024). A survey on the evolution of stream processing systems. *VLDB Journal*, 33(2), 507–541. <https://doi.org/10.1007/s00778-023-00819-8>
- Gotthardt, M., & Mezhyuev, V. (2022). Measuring the Success of Recommender Systems: A PLS-SEM Approach. *IEEE Access*, 10, 30610–30623. <https://doi.org/10.1109/ACCESS.2022.3159652>
- Hoarau-Heemstra, H., Wigger, K., Olsen, J., & James, L. (2023). Cruise tourism destinations: Practices, consequences and the road to sustainability. Dalam *Journal of Destination Marketing and Management* (Vol. 30). Elsevier Ltd. <https://doi.org/10.1016/j.jdmm.2023.100820>
- Hu, M., Zhang, Y., Zhang, H., Lu, Y., Zuo, L., Zhuang, M., Liu, W., Zhang, J., & Zhang, H. (2020). How do Chinese tourists perceive tranquillity during the tour? *Tourism Management Perspectives*, 34. <https://doi.org/10.1016/j.tmp.2020.100666>
- Huang, Z., Lin, X., Liu, H., Zhang, B., Chen, Y., & Tang, Y. (2020). Deep Representation Learning for Location-Based Recommendation. *IEEE Transactions on Computational Social Systems*, 7(3), 648–658. <https://doi.org/10.1109/TCSS.2020.2974534>
- Javadian Sabet, A., Shekari, M., Guan, C., Rossi, M., Schreiber, F., & Tanca, L. (2022). THOR: A Hybrid Recommender System for the Personalized Travel Experience. *Big Data and Cognitive Computing*, 6(4). <https://doi.org/10.3390/bdcc6040131>
- Juan, Z., Zhang, J., & Gao, M. (2024). A multimodal travel route recommendation system leveraging visual Transformers and self-attention mechanisms. *Frontiers in Neurorobotics*, 18. <https://doi.org/10.3389/fnbot.2024.1439195>
- Ko, H., Lee, S., Park, Y., & Choi, A. (2022). A Survey of Recommendation Systems: Recommendation Models, Techniques, and Application Fields. Dalam *Electronics (Switzerland)* (Vol. 11, Nomor 1). MDPI. <https://doi.org/10.3390/electronics11010141>

- Kumar, J., Patra, B. K., Sahoo, B., & Babu, K. S. (2024). Group recommendation exploiting characteristics of user-item and collaborative rating of users. *Multimedia Tools and Applications*, 83(10), 29289–29309. <https://doi.org/10.1007/s11042-023-16799-4>
- Massimo, D., & Ricci, F. (2022). Building effective recommender systems for tourists. *AI Magazine*, 43(2), 209–224. <https://doi.org/10.1002/aaai.12057>
- Nan, X., Kayo Kanato, & Wang, X. (2022). Design and Implementation of a Personalized Tourism Recommendation System Based on the Data Mining and Collaborative Filtering Algorithm. *Computational Intelligence and Neuroscience*, 2022. <https://doi.org/10.1155/2022/1424097>
- Noorian, A. (2024). A personalized context and sequence aware point of interest recommendation. *Multimedia Tools and Applications*, 83(32), 77565–77594. <https://doi.org/10.1007/s11042-024-18522-3>
- Noorian Avval, A. A., & Harounabadi, A. (2023). A hybrid recommender system using topic modeling and prefixspan algorithm in social media. *Complex and Intelligent Systems*, 9(4), 4457–4482. <https://doi.org/10.1007/s40747-022-00958-5>
- Peffer, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A Design Science Research Methodology for Information Systems Research. Dalam *Journal of Management Information Systems* (Vol. 24, Nomor 8). <http://www.tuunanen.fi>.
- Pencarelli, T. (2020). The digital revolution in the travel and tourism industry. *Information Technology and Tourism*, 22(3), 455–476. <https://doi.org/10.1007/s40558-019-00160-3>
- Qassimi, S., & Rakrak, S. (2025). Multi-objective contextual bandits in recommendation systems for smart tourism. *Scientific Reports*, 15(1). <https://doi.org/10.1038/s41598-025-89920-2>
- Ricci, F., Rokach, L., & Shapira, B. (2022). Recommender Systems Handbook: Third Edition. Dalam *Recommender Systems Handbook: Third Edition*. Springer US. <https://doi.org/10.1007/978-1-0716-2197-4>
- Sachi Nandan Mohanty, J. M. C. S. J. A. A. E. P. G. (2020). *Recommender System with Machine Learning and Artificial Intelligence*.
- Shafqat, W., & Byun, Y. C. (2020). A context-aware location recommendation system for tourists using hierarchical LSTM model. *Sustainability (Switzerland)*, 12(10). <https://doi.org/10.3390/su12104107>
- Shambour, Q. Y., Abualhaj, M. M., Abu-Shareha, A. A., & Kharm, Q. M. (2024). PERSONALIZED TOURISM RECOMMENDATIONS: LEVERAGING USER PREFERENCES AND TRUST NETWORK. *Interdisciplinary Journal of Information, Knowledge, and Management*, 19. <https://doi.org/10.28945/5329>

- Shi, X., Liu, Q., Xie, H., Wu, D., Peng, B., Shang, M., & Lian, D. (2023). Relieving Popularity Bias in Interactive Recommendation: A Diversity-Novelty-Aware Reinforcement Learning Approach. *ACM Transactions on Information Systems*, 42(2). <https://doi.org/10.1145/3618107>
- Shuvo, M. I. M., & Islam, M. J. (2024). The digital transformation of tourism: a study of tourist behaviour and preferences in the age of technology in Bangladesh. *Research in Hospitality Management*, 14(3), 236–244. <https://doi.org/10.1080/22243534.2024.2419366>
- Siyamiyan Gorji, A., Hosseini, S., Seyfi, S., Almeida-García, F., Cortes Macías, R., & Mena Navarro, A. (2026). ‘Málaga for living, not surviving’: Resident perceptions of overtourism, social injustice and urban governance. *Journal of Destination Marketing and Management*, 39. <https://doi.org/10.1016/j.jdmm.2025.101044>
- Solano-Barliza, A., Arregocés-Julio, I., Aarón-Gonzalvez, M., Zamora-Musa, R., De-La-Hoz-Franco, E., Escorcia-Gutierrez, J., & Acosta-Coll, M. (2024). Recommender systems applied to the tourism industry: a literature review. Dalam *Cogent Business and Management* (Vol. 11, Nomor 1). Cogent OA. <https://doi.org/10.1080/23311975.2024.2367088>
- Solano-Barliza, A., Valls, A., Acosta-Coll, M., Moreno, A., Escorcia-Gutierrez, J., De-La-Hoz-Franco, E., & Arregoces-Julio, I. (2024). Enhancing Fair Tourism Opportunities in Emerging Destinations by Means of Multi-criteria Recommender Systems: The Case of Restaurants in Riohacha, Colombia. *International Journal of Computational Intelligence Systems*, 17(1). <https://doi.org/10.1007/s44196-024-00700-8>
- Song, Y., & Jiao, X. (2023). A Real-Time Tourism Route Recommendation System Based on Multitime Scale Constraints. *Mobile Information Systems*, 2023. <https://doi.org/10.1155/2023/4586047>
- Suhaim, A. Bin, & Berri, J. (2021). Context-Aware Recommender Systems for Social Networks: Review, Challenges and Opportunities. *IEEE Access*, 9, 57440–57463. <https://doi.org/10.1109/ACCESS.2021.3072165>
- UNWTO. (2021). International Tourism Highlights, 2020 Edition. Dalam *International Tourism Highlights, 2020 Edition*. World Tourism Organization (UNWTO). <https://doi.org/10.18111/9789284422456>
- Wang, R., Wu, Z., Lou, J., & Jiang, Y. (2022). Attention-based dynamic user modeling and Deep Collaborative filtering recommendation. *Expert Systems with Applications*, 188. <https://doi.org/10.1016/j.eswa.2021.116036>
- World Tourism Organization. (2024). *International Tourism Highlights, 2024 Edition*. UN Tourism. <https://doi.org/10.18111/9789284425808>
- Yalcin, E., & Bilge, A. (2021). Investigating and counteracting popularity bias in group recommendations. *Information Processing and Management*, 58(5). <https://doi.org/10.1016/j.ipm.2021.102608>

- Yoon, J. H., & Choi, C. (2023). Real-Time Context-Aware Recommendation System for Tourism. *Sensors*, 23(7). <https://doi.org/10.3390/s23073679>
- Zhao, Y., Wang, Y., Liu, Y., Cheng, X., Aggarwal, C. C., & Derr, T. (2025). Fairness and Diversity in Recommender Systems: A Survey. *ACM Transactions on Intelligent Systems and Technology*, 16(1). <https://doi.org/10.1145/3664928>